

Prédiction des Débits Fluviaux par Machine Learning : cas de la Rivière Inkisi

Patrick NGOSSE¹, Edouard KONZI², Yohanan DZAMA², Boniface MBOLIKO³

¹Institut Supérieur Pédagogique et Technique de Nguya, République Démocratique du Congo

²Université Pédagogique Nationale, République Démocratique du Congo

³Institut Pédagogique de Bandundu, République Démocratique du Congo

Email : patrickngosse@gmail.com, edouardkonzi@gmail.com, yohanan.dzama@upn.ac.cd, bonifacemboliko@gmail.com

RESUME.

Dans cet article, notre objectif est de proposer une approche alliant le « Machine Learning » à des techniques statistiques (Bootstrap) pour affiner la prédiction des débits fluviaux, notamment ceux de la rivière Inkisi. L'hydrologie d'Inkisi, tributaire du fleuve Congo, est influencée par un climat tropical humide et des précipitations abondantes tout au long de l'année. Son hydrogéologie est étroitement liée à la géologie de la région qu'elle traverse. A partir d'une série de données historiques de débits couvrant deux décennies de cette rivière, à savoir : 1950–1969 (période historique), nous avons pu procéder à la prédiction des débits pour les périodes allant de 1970–2023 (période contemporaine) et à celle couvrant 2024–2060 (projection future). Pour ce faire, cinq modèles de Machine Learning ont été appliqués dans cette étude, à savoir : i). Random Forest (RF), ii). Réseau de Neurones (NN), iii). Régression Linéaire (LM), iv). Support Vector Machine (SVM) et v). XGBoost. Chaque modèle a été minutieusement évalué au moyen des métriques RMSE (Root Mean Squared Error) et NSE (Nash-Sutcliffe Efficiency), tandis que les incertitudes entachées à ces mesures ont été quantifiées par l'algorithme Bootstrap pour un arbitrage statistique. Les résultats obtenus révèlent que les modèles RF et XGBoost se démarquent par leurs performances NSE, qui sont supérieures à l'efficacité des autres modèles utilisés, tels que leurs intervalles de confiance entre 0.9781 – 0.9898. Cette étude propose ainsi une approche méthodologique reproductible pour la prédiction des débits fluviaux.

Mots-clés : Prédiction des débits, Apprentissage automatique, Forêt aléatoire, XGBoost, Rivière Inkisi

ABSTRACT.

In this study, we propose an approach that combines **Machine Learning** with statistical techniques (Bootstrap) to enhance the prediction of river streamflows, with a particular focus on the **Inkisi River**. The hydrology of the Inkisi River, a tributary of the Congo River, is influenced by a humid tropical climate and abundant rainfall throughout the year. Its hydrogeology is closely linked to the geology of the region it traverses. Using a historical streamflow dataset spanning two decades (1950–1969, historical period), we carried out predictions for the periods **1970–2023 (contemporary period)** and **2024–2060 (future projection)**. Five Machine Learning models were applied in this study: i) **Random Forest (RF)**, ii) **Neural Network (NN)**, iii) **Linear Regression (LM)**, iv) **Support Vector Machine (SVM)**, and v) **XGBoost**. Each model was rigorously evaluated using the **Root Mean Squared Error (RMSE)** and **Nash-Sutcliffe Efficiency (NSE)** metrics, while the uncertainties associated with these measures were quantified using the **Bootstrap algorithm** to enable robust statistical comparisons. The results reveal that **RF and XGBoost models** outperform the others in terms of NSE performance, with confidence intervals ranging from **0.9781 to 0.9898**. This study thus proposes a reproducible methodological framework for streamflow prediction in complex hydrological contexts.

Keywords: Streamflow Prediction, Machine Learning, Random Forest, XGBoost, Inkisi River

1. INTRODUCTION

La prévision hydrologique, en particulier la prédiction des débits fluviaux, joue un rôle crucial dans la gestion des ressources en eau, la prévention des risques naturels et la planification des infrastructures hydrauliques (Beven, 2012). Dans les régions tropicales humides, où les régimes pluviométriques sont intenses et variables, cette tâche devient encore plus complexe. La rivière Inkisi, affluent important du fleuve Congo, illustre bien cette complexité. Son hydrologie est influencée non seulement par un climat équatorial caractérisé par des précipitations abondantes tout au long de l'année, mais aussi par une géologie contrastée qui conditionne son hydrogéologie (Wamba et al., 2020).

Au cours des deux dernières décennies, le développement de méthodes issues de l'intelligence artificielle, notamment le **Machine Learning (ML)**, a ouvert de nouvelles perspectives dans le domaine de l'hydrologie prédictive (Shortridge et al., 2016 ; Mosavi et al., 2018). Ces techniques, capables d'exploiter des volumes importants de données, permettent de modéliser des relations complexes non linéaires entre les variables hydrologiques. Toutefois, leur application dans les bassins fluviaux tropicaux reste encore limitée, souvent en raison du manque de données fiables et de protocoles d'évaluation standardisés (Sit et al., 2020).

La présente étude s'inscrit dans cette méthodologie. Elle propose une approche hybride qui combine plusieurs algorithmes de ML – Random Forest (RF), Réseau de Neurones (NN), Régression Linéaire (LM), Support Vector Machine (SVM) et XGBoost – avec une analyse statistique rigoureuse des incertitudes par la méthode **Bootstrap**, dans le but de prédire les débits de la rivière **Inkisi**. Ce bassin versant, peu documenté dans la littérature scientifique internationale, offre un cadre d'étude pertinent pour tester la robustesse et la généralisabilité de ces méthodes dans un contexte hydrologique complexe et dynamique.

2. MATERIEL ET METHODES

2.1. Zone d'Étude

D'une longueur d'environ 600 km, la rivière Inkisi prend sa source sur le plateau angolais dans sa partie située au Nord de la ville d'Uíge à 1270 m d'altitude. Dans son cours en territoire angolais, l'Inkisi est dénommée Luquiche et marque la frontière entre plusieurs municipalités de la Province d'Uíge. Son plus grand affluent en Angola est sans doute la rivière Longe qui prolonge sa longueur officielle de 45 km. C'est par la municipalité de Zombo qu'elle quitte le territoire Angolais pour pénétrer en RD Congo par la province du Kongo-Central.

Dans la partie congolaise, celles-ci varient, respectivement, de 30 à 100 m et de 1,5 à 10,0 m. Son débit moyen annuel est estimé à 170 m³/s au niveau du barrage Zongo I. Dans la partie congolaise, le profil longitudinal de la rivière montre une pente moyenne qui augmente de l'amont vers l'aval : 0,4 ‰ de la frontière Angolaise à la cité de Inkisi, 1,5‰ de Inkisi à Sanga, 2,2‰ entre la chute de Sanga et celle de Zongo I, et 20,0‰ de la chute de Zongo II au confluent.

La station hydrométrique de Kisantu sur la rivière Inkisi, sous le pont route-rail est située à l'Ouest de la République Démocratique du Congo (RDC) et au Nord-Ouest de l'Angola, dont les coordonnées GPS sont de : 5°07'41'' latitude Sud et 15°03'59 de longitude Ouest. Le zéro de son échelle limnimétrique est situé à 509,94 m d'altitude par rapport au nivellement de

l'Institut Géographique du Congo. Le bassin versant de cette rivière couvre une superficie de 13 500 km² dont 5 151 km² en RDC.

2.1.1. Hydrologie




Figure 1: Carte de la Rivière Inkisi

L'hydrologie de Inkisi est influencée par un climat tropical humide et des précipitations abondantes tout au long de l'année.

Il en résulte un débit fluvial relativement régulier malgré les évaluations saisonnière. Pendant les saisons pluvieuses, comme pour de nombreux cours d'eau de cette région, le débit de cette rivière est plus élevé avec des variations dans le volume d'eau selon les saisons pluvieuses ou sèches.

2.1.2. Topographie

La rivière Inkisi traverse des terrains variés qui influencent son débit et son régime. Inkisi entre en RDC par une chute et se jette sur le fleuve Congo, en aval du site de Zongo I et Zongo II. Cette topographie influence son régime.

2.1.3. Hydrogéologie

L'hydrogéologie de l'Inkisi, est étroitement liée à la géologie de la région qu'elle traverse. Son bassin versant est caractérisé par une variété des formations géologiques allant des roches sédimentaires aux roches cristallines.

Cette configuration influence la capacité des sols à retenir de l'eau et à alimenter la rivière en eau souterraines. La présence d'aquifères dans son bassin versant contribue à la régularisation de son débit. Les eaux souterraines qui sortent dans les aquifères sont libérées progressivement pour assurer un débit minimum en saison pluvieuse tout comme pendant les saisons sèches. La nature des roches dans la région dans la province Kongo-Central influe sur la capacité des nappes phréatiques et ainsi, sur les aquifères qui alimentent l'Inkisi. En plus virgule, il existe une interaction complexe, entre les eaux du surface de cette rivière et les eaux souterraines des aquifères environnant.

Pendant les pluies, les aquifères sont alimentées par infiltration par les eaux de surfaces tandis que les saisons sèches, les aquifères alimente cette rivière par des sources et des suintements (Google..).

2.2. Méthodologie

La méthodologie développée dans cette étude se décline en plusieurs étapes successives, visant à intégrer de manière cohérente les données historiques, la segmentation temporelle, l'entraînement des modèles de Machine Learning et l'estimation de l'incertitude via Bootstrap.

2.2.1. Préparation des données

Les données utilisées dans cette étude proviennent d'un fichier Excel intitulé `inkisiDB.xlsx`, qui regroupe des mesures quotidiennes de variables hydrologiques essentielles : la date, le niveau d'eau, la hauteur d'eau et le débit, sur une période couvrant deux décennies. Chaque feuille de calcul correspond à une année civile, ce qui permet une intégration naturelle de la dimension temporelle. Le processus de préparation des données comprend les étapes suivantes :

- **Importation et fusion des feuilles** : Toutes les feuilles sont importées puis fusionnées en un jeu de données unique et structuré.
- **Transformation des variables** : Les champs de date sont convertis dans un format temporel standard, et les variables numériques sont normalisées pour garantir leur cohérence.
- **Nettoyage et gestion des valeurs manquantes** : Les enregistrements incomplets ou invalides sont éliminés afin d'assurer la qualité des analyses à venir.

2.2.2. Conversion du niveau d'eau (N) en hauteur (H)

Soit :

- N : Niveau d'eau mesuré (en mètres)
- N_0 : Altitude de référence (en mètres)
- H : Hauteur d'eau (en mètres)

La relation entre le niveau et la hauteur d'eau est donnée par :

$$H = N - N_0 \quad (1)$$

2.2.3. Conversion de Niveau (N) en Hauteur (H)

Soit :

- N : Niveau mesuré (m)
- N_0 : Altitude de référence (m)
- H : Hauteur d'eau (m)

La relation entre N et H est donnée par :

$$H = N - N_0 \quad (1)$$

2.2.4. Conservation du débit Q

Soit :

- $Q(N)$: Débit exprimé en fonction du niveau N
- $Q(H)$: Débit exprimé en fonction de la hauteur d'eau H

Le débit Q est invariant par rapport à la transformation de la variable N en H :

$$Q(H) = Q(N_0 + H) \quad (2)$$

Si la courbe de tarage initiale est donnée par $Q(N)$ et qu'on sait que pour N , alors pour exprimer ce débit en fonction de la hauteur H on peut écrire :

$$Q(H) = Q(N_0 + H) = Q(N) \quad (3)$$

$$Q(H) = Q(N) \quad (4)$$

2.2.5. Intégration dans les modèles d'apprentissage automatique

Lorsqu'on applique des modèles tels que RF, NN, LM, SVM, et XGB, l'entrée H est obtenue à partir de N via :

$$H = N - N_0$$

Ainsi, les modèles deviennent :

- RF ► $Q(H) = F_{RF}(H)$
- NN ► $Q(H) = F_{NN}(H)$
- LM ► $Q(H) = F_{LM}(H)$
- SVM ► $Q(H) = F_{SVM}(H)$
- XGB ► $Q(H) = F_{XGB}(H)$

Cette étape est cruciale pour assurer que l'ensemble des analyses ultérieures repose sur des données fiables, comme recommandé dans plusieurs études de modélisation environnementale (Beven, 2001).

2.2.6. Entraînement des modèles de Machine Learning

Nous avons choisi cinq modèles de Machine Learning afin de couvrir une large gamme de relations (linéaires et non linéaires) :

- **Random Forest (RF)** : Basé sur la création d'arbres décisionnels multiples, ce modèle est reconnu pour sa robustesse et sa capacité à gérer des interactions complexes (Breiman, 2001).

Formalisation : Soit $D = \{(x_i, y_i)\}_{i=1}^n$ un ensemble d'entraînement, la construction de M arbres de décision $\{T_m\}_{m=1}^M$, la prédiction finale est obtenue par moyennage ou vote majoritaire :

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M T_m(x) \quad (5)$$

- **Réseau de Neurones (NN)** : Inspiré du fonctionnement du cerveau humain, ce modèle capture des relations non linéaires à travers des couches de neurones (Haykin, 1999).

Formalisation : Pour une architecture avec L couches cachées, la fonction de perte est donnée par :

$$L(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (6)$$

- **Régression Linéaire (LM)** : Sert de référence pour comparer les performances des modèles plus complexes.

Formalisation : Soit X ensemble des variables explicatives et y les sorties, le modèle linéaire est donné par :

$$\hat{y} = X\beta + \epsilon \quad (7)$$

$$\text{Avec } \beta = (X^T X)^{-1} X^T y \quad (8)$$

- **Support Vector Machine (SVM)** : Optimise la séparation des données dans un espace de haute dimension, utile pour des données non linéaires (Cortes & Vapnik, 1995).

Formalisation : Soit $D = \{(x_i, y_i)\}_{i=1}^n$ un ensemble d'entraînement avec $y_i \in \{-1, +1\}$, l'hyperplan est défini par $f(x) = w^T x + b$, tel que l'optimisation du problème de classification : $\min_{w,b} \frac{1}{2} \|w\|^2$ tel que $y_i(w^T x_i + b) \geq 1, \forall i$. Ainsi, la version non-linéaire :

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j) \quad (9)$$

- **XGBoost (Extreme Gradient Boosting)** : Utilise une approche de boosting pour optimiser la performance de prédiction, en particulier sur de larges ensembles de données (Chen & Guestrin, 2016) :

Formalisation : Avec un arbre de décision f_m à itération m , le modèle prédictif est donné par :

$$\hat{y}_i = \sum_{m=1}^M f_m(x_i) \quad (10)$$

Et la fonction de perte régulière est donnée par :

$$L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i + f_t(x_i)) + \Omega(f_t) \quad (11)$$

Où $\Omega(f_t)$ est un terme de régularisation pour contrôler la complexité du modèle ; en optimisant par descente de gradient :

$$L^{(t)} \approx \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \right] + \Omega(f_t) \quad (12)$$

$$\text{Où } g_i = \frac{\partial l(y_i, \hat{y}_i)}{\partial \hat{y}_i} \text{ et } h_i = \frac{\partial^2 l(y_i, \hat{y}_i)}{\partial \hat{y}_i^2}$$

Chaque modèle est entraîné sur 70 % des données de chaque période, tandis que 30 % sont utilisés pour la validation, conformément aux protocoles standards en Machine Learning (Breiman, 2001).

2.2.7. Estimation de l'incertitude par Bootstrap

Pour quantifier l'incertitude des prévisions, nous appliquons la méthode Bootstrap, qui consiste à générer un grand nombre d'échantillons aléatoires avec remise à partir du jeu de validation (Efron, 1979), si la distribution théorique est de $\hat{\theta}$:

$$SE_{bootstrap} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{(b)} - \bar{\hat{\theta}})^2} \quad (13)$$

$$\text{Où } \bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^{(b)}$$

Pour chaque modèle, nous calculons les métriques RMSE (*Root Mean Squared Error*) et NSE (*Nash-Sutcliffe Efficiency*) sur chacun des échantillons Bootstrap, ce qui nous permet d'obtenir des intervalles de confiance à 95 % pour ces indicateurs :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (14)$$

Si RMSE faible indique une bonne précision du modèle, l'inverse est une imprécision.

Et

$$NSE = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (15)$$

Où y_i est la valeur observée, $\hat{y}_i$ est la valeur modélisée, $\bar{y}$ est la moyenne des observations. S $NSE = 1$ indique une parfaite concordance entre les observations et les prédictions. $NSE = 0$ signifie que le modèle est aussi bon que la moyenne des observations. $NSE = -1$ indique que le modèle est moins performant que la simple moyenne des observations.

2.2.8. Algorithme d'ensemble de prédiction des débits (H-Q)

Entrées :

- X_train, Y_train : données d'entraînement (hauteur H, débit Q)
- X_test : données de test (hauteur H)
- w_model : poids attribués aux modèles (optionnel, sinon déterminés automatiquement)

Étapes :

1. Entraîner les modèles :
 - Modèle_1 $\leftarrow$ Random Forest(X_train, Y_train)
 - Modèle_2 $\leftarrow$ Réseau de Neurones(X_train, Y_train)
 - Modèle_3 $\leftarrow$ Régression Linéaire(X_train, Y_train)
 - Modèle_4 $\leftarrow$ SVM(X_train, Y_train)
 - Modèle_5 $\leftarrow$ XGBoost(X_train, Y_train)
 2. Obtenir les prédictions pour X_test :
 - P1 $\leftarrow$ prédictions de Modèle_1 sur X_test
 - P2 $\leftarrow$ prédictions de Modèle_2 sur X_test
 - P3 $\leftarrow$ prédictions de Modèle_3 sur X_test
 - P4 $\leftarrow$ prédictions de Modèle_4 sur X_test
 - P5 $\leftarrow$ prédictions de Modèle_5 sur X_test
 3. Déterminer les poids (option 1 : automatique, selon performance) :
 - Calculer NSE ou RMSE pour chaque modèle sur un set de validation
 - Convertir les scores en poids normalisés (ex : $w_i = \text{NSE}_i / \text{somme}(\text{NSE}_j)$)
 4. Combiner les prédictions :
 - $P_{\text{final}} \leftarrow w1 \cdot P1 + w2 \cdot P2 + w3 \cdot P3 + w4 \cdot P4 + w5 \cdot P5$
- Sortie :
- P_final : prédictions combinées de débit (Q) pour X_test

2.2.9. Outils logiciels et environnement de calcul

L'ensemble de l'analyse a été réalisé en langage R, en s'appuyant sur des packages spécialisés tels que *readxl*, *dplyr*, *caret*, *randomForest*, *nnet*, *xgboost*, *e1071*, *Metrics*, *ggplot2* et *tidyr*. Ce choix logiciel est justifié par la richesse des bibliothèques disponibles pour le Machine Learning et la manipulation de données, ainsi que par la popularité de R dans la communauté scientifique hydrologique (Beven, 2001).

3. RESULTATS

Ces résultats, résumés dans des tableaux détaillés, soulignent la nécessité d'un arbitrage statistique fondé sur des critères robustes afin de sélectionner le modèle optimal dans un contexte opérationnel (Efron, 1979).

Tableau 1 : Résumé des performances des modèles pendant l'apprentissage de 1950-1969 (avec RMSE et NSE)

N°	Model	RMSE (m3/s)	NSE	Interprétation
1	RF	12.99055	0.9845060117	Très bonne précision et excellente

				performance globale.
2	NN	104.36857	-0.0001092259	Très mauvaise performance : erreurs très élevées, inefficacité totale
3	LM	17.95778	0.9703917136	Bonne performance mais légèrement inférieure à RF et XGB.
4	SVM	13.92045	0.9822084312	Bonne précision, légèrement moins performant que RF et XGB.
5	XGB	13.18053	0.9840495269	Excellente performance, très proche de celle du RF.

Tableau 2 : Résumé des performances des modèles (avec intervalles de confiance à 95 %)

N°	Model	Moyenne RMSE	IC RMSE	Moyenne NSE	IC NSE
1	RF	12.99628	2.5% -97.5% 10.27464 m3/s - 15.83024 m3/s	0.9843011	2.5% - 97.5% 0.9780504 m3/s - 0.9898168 m3/s
2	NN	104.3336	2.5% - 97.5% 100.6914 m3/s - 108.4980 m3/s	- 0.0005439304	2.5% - 97.5% -2.94644e-03 m3/s - - 4.64183e-07m3/s
3	LM	17.94194	2.5% - 97.5% 16.14248 m3/s - 20.22554 m3/s	0.9703191	2.5% - 97.5% 0.9626360 m3/s - 0.9757317 m3/s
4	SVM	13.94767	2.5% - 97.5% 11.72237 m3/s - 16.39154 m3/s	0.9819639	2.5% - 97.5% 0.9752945 m3/s - 0.9875409 m3/s
5	XGB	13.22085	2.5% - 97.5% 10.48912 m3/s - 15.94834 m3/s	0.9837517	2.5% - 97.5% 0.9771294 m3/s - 0.9895019 m3/s

De l'analyse du tableau 2 ci-haut, nous avons relevé que :

1. RF (Random Forest)

- RMSE = **12.99 m³/s** (IC : 10.27 – 15.83)
- NSE = **0.9843** (IC : 0.9781 – 0.9898)

Ce modèle est très performant avec des erreurs faibles, et comporte un très bon ajustement.

2. NN (Neural Network)

- RMSE = **104.33 m³/s** (IC : 100.69 – 108.50)
- NSE = **-0.0005** (IC : -0.00295 – -0.00000046)

Avec des erreurs importantes, le NSE de NN proche de zéro voire négatif, nous constatons que ce modèle n'est non adapté.

3. LM (Linear Model)

- RMSE = **17.94 m³/s** (IC : 16.14 – 20.23)
- NSE = **0.9703** (IC : 0.9626 – 0.9757)

Malgré le bon résultat de LM, son NSE est inférieur aux autres modelés.

4. SVM (Support Vector Machine)

- RMSE = **13.95 m³/s** (IC : 11.72 – 16.39)
- NSE = **0.9820** (IC : 0.9753 – 0.9875)

Il est à noter que, quelque soit les résultats obtenus, pour le modèle SVM, son NSE est inférieur aux résultats obtenus par le RF et XGB.

5. XGB (XGBoost)

- RMSE = **13.22 m³/s** (IC : 10.49 – 15.95)
- NSE = **0.9838** (IC : 0.9771 – 0.9895)

Pour le modèle XGB, on remarque qu'il est mieux adapté aux données des débits de ce site, que nous avons exploitées.

3.1. Performances des modèles sur chaque période

Période 1950–1969 : Les données (moyennes annuelles) historiques pour entraîner des modèles « complets » et générer des scénarios futurs :

Tableau 3 : Moyenne Annuelle des Données Historiques

Année	N(m)	H(m)	Q(m ³ /s)
1950	516,07	6,14	232,85
1951	515,87	5,93	210,40
1952	515,95	6,01	217,09
1953	515,99	6,05	219,98
1954	515,73	5,79	188,42
1955	516,00	6,06	224,56
1956	515,49	5,55	164,55
1957	515,45	5,51	163,66
1958	515,02	5,08	118,63
1959	515,36	5,42	152,44
1960	515,56	5,62	175,18
1961	515,82	5,88	199,71
1962	515,32	5,38	148,23
1963	515,25	5,31	141,67
1964	515,50	5,56	171,82
1965	515,36	5,42	151,64
1966	515,77	5,83	200,50
1967	515,70	5,76	189,28
1968	515,40	5,46	155,46
1969	515,44	5,50	161,13

Pour chaque période, les modèles ont été évalués sur le jeu de validation en termes de RMSE et NSE, avec des intervalles de confiance calculés par bootstrap.

Période 1970–2023 : Les données (moyennes annuelles) contemporaines pour compléter les données historiques.

- Les simulations futures indiquent une évolution de la relation tarage. Bien que les intervalles de confiance se soient élargis – signe d'une plus grande incertitude – certains modèles, notamment RF et XGBoost, continuent de fournir des prédictions acceptables malgré l'augmentation de la variabilité (Chen & Guestrin, 2016).

Tableau 4 : Moyenne Annuelle des Données Contemporaines

Année	Niveau N(m)	H(m)	Q_RF(m3/s)	Q_NN(m3/s)	Q_LM(m3/s)	Q_SVM(m3/s)	Q_XGB(m3/s)
1970	515,54	5,55	174,38	179,37	172,85	166,91	181,26
1971	515,53	5,70	182,50	179,37	170,71	165,63	182,63
1972	515,57	5,67	184,37	179,37	176,18	168,91	187,35
1973	515,63	5,70	187,86	179,37	182,14	176,37	193,84
1974	515,63	5,63	184,31	179,37	182,36	174,80	191,41
1975	515,65	5,66	187,51	179,37	184,23	177,90	193,98
1976	515,58	5,63	180,76	179,37	176,28	169,44	184,93
1977	515,59	5,72	185,13	179,37	177,52	171,16	189,52
1978	515,54	5,57	176,67	179,37	172,36	165,59	181,85
1979	515,55	5,59	177,19	179,37	173,26	166,02	180,64
1980	515,58	5,61	179,99	179,37	177,34	170,14	186,07
1981	515,63	5,59	181,50	179,37	182,72	176,60	193,45
1982	515,67	5,67	189,13	179,37	186,37	179,69	195,06
1983	515,65	5,59	184,13	179,37	185,00	178,82	195,75
1984	515,60	5,65	183,09	179,37	178,60	171,93	187,40
1985	515,54	5,71	182,47	179,37	171,98	164,82	182,77
1986	515,56	5,63	180,46	179,37	174,60	168,33	183,12
1987	515,57	5,58	179,20	179,37	175,35	168,36	183,98
1988	515,68	5,71	190,04	179,37	187,76	182,00	197,92
1989	515,56	5,67	181,68	179,37	174,36	167,74	184,54
1990	515,63	5,69	185,97	179,37	182,24	174,86	189,99
1991	515,62	5,66	183,66	179,37	181,02	174,83	190,03
1992	515,66	5,68	188,54	179,37	185,63	177,95	193,79
1993	515,61	5,54	178,19	179,37	179,88	173,85	189,44
1994	515,58	5,65	181,60	179,37	177,14	171,21	187,00
1995	515,67	5,68	187,79	179,37	186,98	180,36	198,41
1996	515,70	5,70	191,34	179,37	190,22	184,39	199,29
1997	515,56	5,64	179,91	179,37	174,13	167,50	182,27
1998	515,62	5,70	187,31	179,37	180,94	174,00	189,52
1999	515,58	5,70	183,74	179,37	177,20	169,33	185,70
2000	515,69	5,64	187,53	179,37	189,61	183,95	201,17
2001	515,58	5,64	180,91	179,37	177,20	170,82	185,86
2002	515,62	5,76	189,58	179,37	181,30	175,41	190,83

2003	515,58	5,74	185,91	179,37	176,48	169,98	187,25
2004	515,53	5,66	181,04	179,37	171,63	165,21	181,50
2005	515,62	4,23	182,65	179,30	180,73	173,11	188,26
2006	515,67	5,63	185,76	179,37	186,64	179,86	195,20
2007	515,58	5,59	181,10	179,37	177,29	169,83	185,51
2008	515,60	5,60	181,92	179,37	179,43	172,37	187,93
2009	515,62	5,64	183,91	179,37	181,03	173,99	189,90
2010	515,61	5,59	182,07	179,37	180,54	174,32	189,01
2011	515,66	4,20	184,49	179,30	185,55	179,51	194,12
2012	515,57	5,67	182,84	179,37	175,84	169,66	184,24
2013	515,64	5,71	186,66	179,37	182,99	176,93	194,40
2014	515,59	5,71	185,36	179,37	178,25	171,18	187,81
2015	515,59	5,73	186,12	179,37	178,27	170,98	186,97
2016	515,52	5,66	179,85	179,37	170,57	164,41	181,19
2017	515,49	5,61	175,52	179,37	166,62	160,21	177,18
2018	515,57	5,67	183,37	179,37	175,71	169,69	185,77
2019	515,63	5,71	186,12	179,37	182,61	175,25	191,18
2020	515,63	5,73	188,48	179,37	182,03	176,02	192,28
2021	515,63	5,73	188,92	179,37	182,61	176,71	193,11
2022	515,65	5,83	194,23	179,37	184,81	178,20	194,59

Période 2024–2060 : Les données (moyennes annuelles) contemporaines pour compléter les données historiques.

- Le modèle **Random Forest** a affiché un RMSE moyen faible et un NSE élevé, confirmant sa capacité à modéliser les relations complexes (Breiman, 2001).
- Le **Réseau de Neurones** a présenté des performances comparables, bien que la variabilité des résultats soit légèrement plus importante (Haykin, 1999).
- La **Régression Linéaire**, utilisée en référence, montre des limites dans le traitement des non-linéarités.
- Le modèle **SVM** a offert une alternative intéressante, même si ses résultats étaient moins stables.
- **XGBoost** a obtenu des performances remarquables, avec des intervalles de confiance étroits, indiquant une forte robustesse (Chen & Guestrin, 2016).

Tableau 5 : Moyenne Annuelle de la Projection future


Année	Niveau N(m)	H(m)	Q_RF(m3/s)	Q_NN(m3/s)	Q_LM(m3/s)	Q_SVM(m3/s)	Q_XGB(m3/s)
2024	515,66	5,66	187,89	179,37	185,99	178,86	194,98
2025	515,62	5,64	182,80	179,37	181,02	173,92	187,75
2026	515,62	5,66	185,28	179,37	181,37	176,33	192,20
2027	515,57	5,63	181,56	179,37	176,25	169,08	185,71
2028	515,69	5,60	185,23	179,37	189,24	182,52	198,79
2029	515,57	4,20	178,21	179,30	175,99	168,86	183,93
2030	515,57	5,73	184,92	179,37	175,42	168,91	186,72
2031	515,53	5,75	183,36	179,37	171,39	165,88	181,75
2032	515,61	5,67	184,18	179,37	179,82	173,03	189,09
2033	515,65	5,66	184,47	179,37	184,26	177,37	194,36
2034	515,51	5,65	177,35	179,37	169,03	163,00	179,52
2035	515,60	5,63	180,93	179,37	179,30	171,55	187,89
2036	515,59	5,66	182,72	179,37	178,34	172,27	188,76
2037	515,60	5,63	181,52	179,37	179,36	172,81	188,52
2038	515,71	5,66	188,98	179,37	191,76	183,29	198,52
2039	515,58	5,67	184,64	179,37	176,61	170,61	185,77
2040	515,69	5,68	190,56	179,37	189,24	182,73	198,65
2041	515,65	5,67	186,99	179,37	184,22	177,56	193,55
2042	515,67	5,64	185,35	179,37	186,76	180,60	196,38
2043	515,64	5,66	184,97	179,37	183,43	177,91	192,61
2044	515,55	5,63	179,61	179,37	173,04	167,35	183,57
2045	515,54	5,62	177,60	179,37	171,86	165,20	181,59
2046	515,54	5,69	181,58	179,37	172,07	164,90	181,02
2047	515,58	5,71	184,67	179,37	176,80	169,78	185,75
2048	515,59	5,73	186,38	179,37	178,45	172,80	187,34
2049	515,56	5,73	183,92	179,37	174,11	167,39	183,54
2050	515,62	5,68	185,16	179,37	181,78	174,77	190,35
2051	515,62	5,60	181,75	179,37	181,53	174,10	190,49
2052	515,66	5,75	190,53	179,37	185,36	179,16	196,46
2053	515,62	5,72	186,57	179,37	181,34	175,37	192,57
2054	515,64	5,72	187,21	179,37	182,95	174,45	190,12
2055	515,65	5,68	187,43	179,37	184,71	177,89	194,56
2056	515,56	5,76	186,25	179,37	174,50	168,07	185,33
2057	515,57	5,59	178,38	179,37	175,88	167,78	183,63
2058	515,54	5,64	179,71	179,37	172,38	165,64	180,25
2059	515,62	5,69	186,19	179,37	180,87	173,90	190,67
2060	515,62	5,64	184,54	179,37	181,58	173,73	189,00

3.2. Analyse graphique des courbes de tarage


Les courbes de tarage représentent visuellement la relation entre le niveau, la hauteur et le débit et permettent d'identifier les évolutions temporelles :

- **Période Historique :**




La courbe historique, ajustée par une régression linéaire, présente une relation régulière et stable entre H et Q, fournissant une base de référence pour les analyses ultérieures (Beven, 2001).






Qui se présente en hydrogramme ci-dessous :






Modèle RF



Modèle NN




Modèle LM




Modèle SVM


1970-2023




2024-2060




Hydrogramme (1970-2023) — SVM



Hydrogramme (2024-2060) — SVM




Modèle XGB



Les simulations futures indiquent une possible modification de la sensibilité du débit aux variations de la hauteur, avec des scénarios potentiellement divergents en fonction des conditions climatiques futures (IPCC, 2014).

Qui se présente en hydrogramme ci-dessous :



3.3. Synthèse des résultats

L'analyse des performances numériques et graphiques permet de dégager plusieurs constats clés :

- *Excellente performance prédictive :*
Les deux modèles ont des NSE très élevés (> 0.984), ce qui signifie qu'ils expliquent plus de 98 % de la variance des observations — un niveau très rare et satisfaisant en hydrologie.
- *RMSE très bas :*
RF (12.99 m³/s) et XGB (13.18 m³/s) présentent les plus faibles erreurs absolues, ce qui garantit une précision fiable dans les prévisions quotidiennes ou mensuelles.
- *Robustesse face à la non-linéarité :*
Les processus hydrologiques sont souvent complexes et non linéaires (interactions pluie-débit, infiltration, évapotranspiration, etc.). RF et XGB, qui sont des modèles d'ensemble, sont spécialement conçus pour gérer ce type de complexité.
- *Stabilité et faible sensibilité au surapprentissage :*
Contrairement aux réseaux de neurones, RF et XGB sont plus stables, surtout dans des contextes avec peu de données ou de bruit, ce qui est courant dans les bassins tropicaux.

Pour les autres modèles :

- SVM : Bien qu'efficace, il reste légèrement moins performant et peut être plus difficile à paramétrer correctement pour des projections longues.
- LM : Trop simple pour capturer les dynamiques non linéaires d'un bassin tropical.
- NN : Clairement non fiable ici (NSE négatif), probablement en raison d'un manque de tuning ou de données adaptées.

Ces résultats ouvrent la voie à une discussion approfondie sur l'adaptation des modèles prédictifs aux scénarios futurs et sur l'importance d'intégrer des mesures d'incertitude dans la prise de décision en gestion de l'eau.

4. DISCUSSION

4.1. Arbitrage entre modèles : une analyse fondée sur la performance et la robustesse

L'évaluation comparative des cinq modèles testés s'inscrit dans une logique d'arbitrage statistique, c'est-à-dire de sélection raisonnée basée sur des indicateurs objectifs de performance et d'incertitude. Les résultats démontrent clairement la supériorité des modèles d'ensemble, en particulier Random Forest (RF) et XGBoost (XGB), qui se distinguent par leurs faibles erreurs quadratiques moyennes (RMSE < 13.2 m³/s) et leurs très hauts coefficients

d'efficacité de Nash-Sutcliffe ($NSE > 0.984$). Ces modèles tirent parti de leur capacité à intégrer des interactions complexes et non linéaires, tout en limitant l'impact des valeurs aberrantes (Breiman, 2001 ; Chen & Guestrin, 2016).

En revanche, le réseau de neurones (NN), bien que performant théoriquement, présente une variabilité importante de ses résultats selon les configurations, traduisant une sensibilité aux hyperparamètres et un risque accru de surapprentissage (Haykin, 1999). Cette instabilité réduit sa pertinence dans un cadre d'arbitrage statistique rigoureux, où la fiabilité des performances est aussi déterminante que leur niveau absolu.

Le modèle de régression linéaire (LM), plus simple, reste limité par son incapacité à modéliser les relations non linéaires caractéristiques des bassins tropicaux. Néanmoins, il fournit un point de comparaison utile dans le processus d'évaluation. Quant au SVM, ses performances intermédiaires et sa dépendance aux choix de noyaux rendent son application moins robuste, notamment face à la variabilité interannuelle du signal hydrologique (Cortes & Vapnik, 1995).

Dans ce contexte, le recours à des critères statistiques précis et des marges d'incertitude explicites devient essentiel pour éclairer l'arbitrage entre modèles.

4.2. Le bootstrap : un levier pour un arbitrage probabiliste

L'intégration de la technique de bootstrap renforce la validité de l'arbitrage statistique en fournissant des intervalles de confiance à 95 % sur les métriques de performance (RMSE, NSE). Cette approche non paramétrique, fondée sur la rééchantillonnage du jeu de validation, permet de générer des distributions empiriques des erreurs et de quantifier la variabilité intrinsèque des prédictions (Efron, 1979).

Ainsi, au-delà des valeurs ponctuelles, le bootstrap offre une vision probabiliste de la performance des modèles, élément crucial pour la prise de décision en contexte d'incertitude hydrologique. Les gestionnaires peuvent ainsi pondérer leur choix de modèle en tenant compte non seulement de l'efficacité moyenne, mais aussi de la stabilité statistique des prédictions. Par exemple, bien que les modèles RF et XGB affichent des NSE proches, leurs intervalles de confiance étroits les rendent plus fiables dans un cadre opérationnel que des modèles à variance plus élevée comme le NN.

4.3. Limites de l'arbitrage et pistes d'amélioration

Complexité des modèles et risque de surapprentissage :

Les modèles comme XGBoost ou les réseaux de neurones, bien que performants, présentent un risque accru de suradaptation aux données historiques, en particulier en l'absence de régularisation ou de validation croisée approfondie (Haykin, 1999 ; Chen & Guestrin, 2016).

L'arbitrage statistique pourrait être renforcé par une évaluation complémentaire de la généralisation sur des jeux indépendants ou des bassins similaires.

Ces limitations ouvrent des pistes de recherche futures visant à enrichir les jeux de données, à développer des modèles plus robustes et à intégrer des scénarios climatiques détaillés.

5. CONCLUSION

Cette étude a proposé une approche intégrée combinant algorithmes de Machine Learning et quantification de l'incertitude par bootstrap pour améliorer la prédiction des débits fluviaux à partir de la relation hauteur-débit (H-Q). En structurant l'analyse autour de trois périodes temporelles distinctes – 1950–1969, 1970–2023, et 2024–2060 – nous avons mis en évidence des évolutions significatives dans la dynamique hydrologique du bassin de l'Inkisi, susceptibles de traduire les effets conjoints du changement climatique et des modifications anthropiques.

Les principaux résultats peuvent être synthétisés selon un arbitrage statistique fondé sur deux indicateurs-clés (RMSE et NSE), accompagnés de leurs intervalles de confiance :

- Les modèles Random Forest (RF) et XGBoost (XGB) se distinguent par leur excellente performance prédictive ($NSE \approx 0.984$) et leur faible erreur de prédiction ($RMSE < 13.2 \text{ m}^3/\text{s}$), tout en conservant une robustesse élevée à travers les périodes analysées.
- Le modèle SVM présente des performances acceptables, quoique légèrement inférieures, notamment en termes de stabilité.
- La régression linéaire (LM), bien que moins performante dans un système non linéaire comme l'hydrologie tropicale, conserve un intérêt en tant que modèle de référence simple et interprétable.
- Le réseau de neurones (NN) a montré une inadéquation marquée dans ce contexte : NSE négatif et RMSE très élevé, suggérant une mauvaise capture de la dynamique hydrologique.

L'apport majeur de cette étude réside dans l'introduction d'un cadre d'arbitrage statistique robuste, combinant performance moyenne et incertitude probabiliste via bootstrap, pour orienter la sélection de modèles dans un cadre de gestion de l'eau informé et reproductible.

Enfin, des pistes de recherche prometteuses se dégagent, notamment :

- l'intégration de variables explicatives supplémentaires (pluviométrie, rugosité, occupation des sols),
- le couplage avec des modèles physiques ou hydrodynamiques,
- et l'incorporation de scénarios climatiques prospectifs pour fiabiliser les projections à long terme.

Ce cadre peut ainsi être généralisé à d'autres bassins et mis au service d'une modélisation hydrologique plus résiliente et opérationnelle, dans un contexte de changement global.

6. REFERENCES

1. **Beven, K.** (2001). *Environmental Modelling: An Uncertainty Analysis*. John Wiley & Sons.
2. **Chen, T. & Guestrin, C.** (2016). XGBoost: A Scalable Tree Boosting System. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794).
3. **Cortes, C. & Vapnik, V.** (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
4. **Efron, B.** (1979). Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, 7(1), 1–26.
5. **Haykin, S.** (1999). *Neural Networks: A Comprehensive Foundation* (2nd ed.). Prentice Hall.
6. **IPCC.** (2014). *Climate Change 2014: Synthesis Report*. Contribution of Working Groups I, II and III to the Fifth Assessment Report of the Intergovernmental Panel on Climate Change. Geneva, Switzerland: IPCC.
7. **Montanari, A., et al.** (2004). Probabilistic forecasts of hydrological extremes in a
8. **Beven, K.** (2012). *Rainfall-Runoff Modelling: The Primer*. Wiley-Blackwell.
9. **Shortridge, J. E., Guikema, S. D., & Zaitchik, B. F.** (2016). *Machine learning for streamflow prediction: Comparing random forests and support vector machines*. *Water Resources Research*, 52(4), 2954–2969.
10. **Mosavi, A., Ozturk, P., & Chau, K. W.** (2018). *Flood prediction using machine learning models: Literature review*. *Water*, 10(11), 1536.
11. **Sit, M., Demir, I.** (2020). Current practices in data-driven modeling of hydrological processes. *Environmental Modelling & Software*, 124, 104588.
12. **Zhang, X., Tang, Q., Wang, S., Leng, G.** (2019). Machine learning models for streamflow forecasting: A comparative study. *Journal of Hydrology*, 575, 343–355.
13. **Chen, T., & Guestrin, C.** (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, 785–794.
14. **Wamba, C., Ilunga, D., & Mabiala, M.** (2020). Hydrological characteristics of the Inkisi River basin. *African Journal of Hydrology*, 5(2), 45–59.
15. **Breiman, L.** (2001). Random Forests. *Machine Learning*, 45(1), 5–32.