

Amélioration de la prévision des crues par l'utilisation de réseaux de neurones récurrents de type LSTM : étude de cas du bassin versant de l'Ill et de la Sarre

Improving flood forecasting using LSTM recurrent neural networks: case study of the Ill and Sarre watersheds

■ L. WEBER¹, X. JURADO¹, T.H.L. NGUYEN^{1,2}, L. MAURER^{2,3}, E. REIMINGER⁴, C. WEMMERT², N. REIMINGER^{1,2*}

¹ AIR&D – Strasbourg

² Laboratoire ICube (UMR 7357) – Illkirch-Graffenstaden

³ École nationale du génie de l'eau et de l'environnement de Strasbourg (Engees) – Strasbourg

⁴ Syndicat des Eaux et de l'Assainissement Alsace-Moselle (SDEA) – Schiltigheim

Mots-clés :

Prévision

Crue

Inondation

Hauteur d'eau

Apprentissage automatique

Intelligence artificielle

RÉSUMÉ

Les inondations représentent les catastrophes naturelles les plus fréquentes dans le monde, et leur intensité devrait s'accroître en raison du changement climatique, rendant crucial le défi de limiter leurs impacts humains et économiques dévastateurs. L'anticipation des crues constitue une stratégie clé pour atténuer ces risques, nécessitant des modèles et outils de prévision toujours plus performants. En France, la prévision des crues repose principalement sur des modèles hydrologiques traditionnels basés sur des données empiriques ou des principes physiques, tandis que les modèles d'intelligence artificielle (IA) et d'apprentissage automatique (ML), qui offrent des avantages en matière de précision et de rapidité, ne sont pas encore pleinement intégrés dans la gestion des inondations à l'échelle nationale. Une étude récente a mis en lumière le potentiel des modèles d'ensemble, tels que le *Random Forest* (RF) et le *Gradient Boosting* (GB), pour prévoir les crues sur deux stations hydrométriques du bassin de l'Ill. La présente étude vise à évaluer l'intérêt des modèles d'IA plus avancés, en particulier des réseaux de neurones récurrents (RNN) de type LSTM (*Long Short-Term Memory*), pour améliorer la prévision des hauteurs d'eau à 24 heures. Ces modèles utilisent des données hydrométriques (hauteur et débit des cours d'eau) et météorologiques (précipitations, humidité, température) enregistrées à un pas de temps horaire. Les résultats montrent que ces données publiques permettent une représentation précise de la dynamique hydrologique locale, et que les modèles LSTM surpassent les modèles RF et GB dans la précision de prévision à 24 heures. Ce travail démontre le potentiel des algorithmes d'IA avancés pour renforcer la prévision des crues en France en complément des modèles traditionnels et souligne l'importance d'intégrer ces outils dans les stratégies de gestion des risques d'inondation.

Keywords:

Forecasting

Flood

Water level

Machine learning

Artificial Intelligence

ABSTRACT

Floods are the most frequent natural disasters worldwide, and their intensity is expected to increase due to climate change, making it crucial to address the challenge of minimizing their devastating human and economic impacts. Flood forecasting is thus a key strategy for mitigating these risks, requiring increasingly effective models and prediction tools. In France, flood forecasting primarily relies on traditional hydrological models based on empirical data or physical principles, while artificial intelligence (AI) and machine learning (ML) models—which offer advantages in terms of accuracy and speed—have not yet been fully integrated into national flood management. A recent study highlighted the potential of ensemble models, such as *Random Forest* (RF) and *Gradient Boosting* (GB), for forecasting floods at two hydrometric stations in the Ill River basin. The present study aims to evaluate the benefits of more advanced AI models, specifically *Long Short-Term Memory* (LSTM) recurrent neural networks (RNN), for improving 24-hour water level forecasts. These models utilize hydrometric data (water height and river flow) and meteorological data (precipitation, humidity, temperature) recorded at hourly intervals. The results show that this publicly available data enables an accurate representation of local hydrological dynamics, and that LSTM models outperform RF and GB models in 24-hour forecasting accuracy. This work demonstrates the potential of advanced AI algorithms to enhance flood forecasting in France, complementing traditional models, and emphasizes the importance of incorporating these tools into flood risk management strategies.

Introduction

Les inondations sont un phénomène naturel ayant un impact dévastateur sur la vie humaine, les infrastructures et l'économie [MOSAVI et al., 2018], ainsi que sur la santé des populations exposées de manière récurrente. Leur intensification récente rend leur anticipation

cruciale. En France, 17,1 millions de personnes sont exposées au risque d'inondation par débordement des cours d'eau, un aléa représentant 60 % des indemnités au titre des catastrophes naturelles pour un coût de 7,3 milliards d'euros [CCR, 2021]. Les inondations de juillet 2021 en Europe de l'Ouest, causées par des précipitations extrêmes (jusqu'à 150 mm en 15-18 heures) et des crues de période de retour d'environ 400 ans, ont

* Auteur correspondant – Courriel : nreiminger@air-d.fr

entraîné des dommages estimés à plus de 32 milliards d'euros [MOHR et al., 2023]. Le changement climatique, la croissance démographique, l'urbanisation et l'imperméabilisation des sols aggravent le risque d'inondation [ZHENG et HUANG, 2023]. Le sixième rapport du Groupe d'experts intergouvernemental sur l'évolution du climat (GIEC) en 2023 prévoit une augmentation de la fréquence des inondations côtières, des précipitations extrêmes et des crues soudaines dues aux fortes pluies [CALVIN et al., 2023].

La surveillance, la prévision ainsi que l'alerte en cas de crue sont essentielles pour sauver des vies et limiter les pertes matérielles [LIU et al., 2020]. Les systèmes d'alerte précoce jouent un rôle central dans la gestion du risque inondation, au-delà des mesures structurelles [BYARUHANGA et al., 2024]. Dans le contexte de l'urbanisation croissante et du changement climatique, et pour minimiser les dommages des inondations, il est ainsi crucial d'améliorer les modèles de prévision des crues pour fournir aux gestionnaires de crise des informations fiables et rapidement exploitables [DA SILVA et al., 2022]. La prévision des hauteurs d'eau joue alors un rôle majeur pour la gestion de crise et le pilotage des ouvrages [SAPITANG et al., 2020], car des prévisions fiables permettent des stratégies d'évacuation plus efficaces [KUN XIE et al., 2017].

Les modèles de prévision des crues se divisent principalement en deux types : ceux basés sur la physique et ceux basés sur les données [NUR ADLI ZAKARIA et al., 2021]. Les modèles basés sur la physique décrivent les processus hydrologiques, mais requièrent des informations spécifiques sur chaque bassin. Les modèles basés sur les données, quant à eux, utilisent des historiques de niveaux d'eau, débits et précipitations pour créer des modèles statistiques prédictifs. En France, les services de prévision des crues (SPC) utilisent les modèles **GRP** (génie rural pour la prévision des crues) et **Larsim** (*large area run-off simulation model*), notamment dans le Grand Est. Le modèle **GRP**, basé sur les données, est utilisé pour des prévisions à court terme en s'appuyant sur des réseaux de mesure [VIATGÉ et al., 2019; TIBERI-WADIER et al., 2021]. **Larsim**, un modèle basé sur la physique, décrit les processus d'écoulement continu et modélise les principaux aspects du cycle de l'eau [LEG, 2019; ISHIKAWA et al., 2021].

Depuis les premières applications de l'intelligence artificielle (IA) en hydrologie dans les années 1990, avec notamment des travaux pionniers démontrant le potentiel des réseaux neuronaux pour les modèles pluie-débit [HSU et al., 1995], la recherche dans cette thématique a

connu des avancées. Ces premiers travaux étaient toutefois limités par les problèmes de surparamétrage et de surcalage, freinant l'adoption généralisée des méthodes d'apprentissage automatique [GAUME et GOSSET, 2003]. Par la suite, l'équipe de Kratzert a démontré la supériorité des modèles basés sur le *machine learning*, en particulier les réseaux de type *long short-term memory* (**LSTM**) initiés par HOCHREITER et SCHMIDHUBER [1997], en comparaison des approches traditionnelles pluie-débit [KRATZERT et al., 2018]. Ces travaux, combinant des données hydrologiques de longue durée et des techniques avancées d'apprentissage séquentiel, ont ouvert la voie à une adoption plus large des modèles d'intelligence artificielle en hydrologie, en répondant efficacement aux limites des approches antérieures. Les recherches ultérieures de ces chercheurs ont élargi l'utilisation des **LSTM** en introduisant des méthodes pour intégrer des informations spatiales et combiner des données hydrologiques et climatiques globales, renforçant ainsi la robustesse et l'interprétabilité des prévisions hydrologiques [GAUCH et al., 2021; NEVO et al., 2022]. Ces contributions ont été déterminantes pour dépasser les limites historiques des modèles d'IA en hydrologie, en plaçant les **LSTM** comme une référence dans la prévision des crues et des débits. D'autres approches innovantes basées sur l'apprentissage automatique (ML, *machine learning*) et l'intelligence artificielle ont également démontré leur efficacité et leur précision, tout en réduisant la complexité de mise en œuvre. Ces méthodes, parfois associées à des images satellite ou radar pour produire des cartes de zones inondables [MUNAWAR et al., 2022], ou à des capteurs de terrain [AMNATSAN et al., 2018; MOSAVI et al., 2018; KHAI et al., 2019], sont souvent utilisées en complément des modèles traditionnels [JINGMING HOU et al., 2021]. Les réseaux de neurones artificiels, tels que les *multi-layer perceptrons* (**MLP**) [AMNATSAN et al., 2018; ZEYNODDIN et al., 2020], les systèmes **ANFIS** (*adaptive neuro fuzzy inference system*) [KALOOP et al., 2017; ÜNEŞ et al., 2019], et les machines à vecteurs de support (**SVM**) [KHAI et al., 2019; KIM et KIM, 2021] sont par exemple également fréquemment utilisés. L'utilisation de modèles d'ensemble, tels que le *gradient boosting* (**GB**) et le *random forest* (**RF**), apparaît également dans la littérature scientifique, bien que leur utilisation reste beaucoup moins fréquente [WEE et al., 2021; HAKIM et al., 2024]. Toutefois, pour les données temporelles ou séquentielles telles qu'il est question en prévision des crues, le modèle **LSTM** reste particulièrement performant, surpassant souvent les autres modèles comme le **MLP** ou le **SVR**

[HU et al., 2020; HAKIM et al., 2024]. On notera enfin que toutes ces utilisations du machine learning et de l'intelligence artificielle pour la prévision des crues sont au stade de la recherche, et ne font pas encore aujourd'hui l'objet d'une utilisation opérationnelle en France.

Enfin, il est à noter que les performances de ces modèles sont généralement évaluées à l'aide de critères statistiques comme le coefficient de détermination (R^2) [PIRI et KAHKHA, 2016; SHAMIM et al., 2016], l'erreur quadratique moyenne (RMSE) [ZHANG et al., 2018; ZHU et al., 2020], et l'erreur absolue moyenne (MAE) [DAS et al., 2016; ZAJI et al., 2018]. L'utilisation de critères hydrologiques spécifiques tels que le coefficient de Nash-Sutcliffe (NSE) reste marginale [IBRAHIM et al., 2022]. D'autres critères, comme le *persistence index* (PI) ou le *critical success index* (CSI), sont également trop peu utilisés, bien qu'ils apportent une information beaucoup plus pertinente pour valider les modèles hydrologiques [KIM et KIM, 2021]. En effet, il a récemment été démontré qu'il est crucial de tenir compte des critères de performances hydrologiques en plus des critères statistiques habituels pour développer des modèles performants de prévision des crues basés sur l'IA et l'apprentissage automatisé [REIMINGER et al., 2024].

Cette étude fait suite à un précédent travail portant sur l'évaluation des performances de l'IA et de l'apprentissage automatique pour la prévision des crues sur des cas d'étude du bassin versant de l'Ill (Alsace, France). Dans cette nouvelle étude, l'accent est mis sur l'utilisation d'algorithmes d'IA plus complexes et théoriquement plus adaptés à la compréhension des données séquentielles telles que les données hydrologiques et météorologiques. En particulier, les performances du modèle **LSTM** sont étudiées et comparées à celles des modèles d'ensemble **RF** et **GB** au niveau de quatre stations de prévision des crues situées au Alsace-Moselle dans le cadre de prévisions à 24 heures. Les performances des modèles sont évaluées à la fois selon des critères statistiques classiques (R^2 , MAE, RMSE), et selon des critères hydrologiques spécifiques (NSE, PI, CSI et TDAb), offrant une approche originale, mieux adaptée aux caractéristiques des phénomènes hydrologiques. Les modèles sont alimentés uniquement par des données publiques hydrodynamiques et climatiques, sans spatialisation. La section 1 détaille le contexte de l'étude, les algorithmes utilisés et leur paramétrage, ainsi que les critères de performance retenus, tandis que les résultats et leur discussion sont présentés en section 2.

1. Matériels et méthodes

1.1. Sites d'étude

L'étude a été menée sur quatre stations de prévision des crues situées respectivement dans les villes de Sarrebourg (SRG) (6 856 193,035/997 723,654 Lambert-93), Kogenheim (KG) (6 813 774,873/1 036 738,924 Lambert-93), Waltenheim-sur-Zorn (appelée Waltenheim, WLT) (6 859 940/1 040 493 Lambert-93), et Strasbourg (appelée Chasseur-Froid, CF) (6 846 431,958/1 052 521,466 Lambert-93) dans la région Grand Est. Ces stations font partie du réseau surveillé par le service de prévisions des crues (SPC) de la Dreal (Direction régionale de l'environnement, de l'aménagement et du logement) du Grand Est, et sont situées sur les cours d'eau de la Sarre pour Sarrebourg, de l'Ill pour Kogenheim et Chasseur-Froid, et de la Zorn pour Waltenheim. D'après les informations obtenues de la Dreal Grand Est, pour leurs modèles hydrologiques et pour une échéance de prévision de 24 heures, les stations de Kogenheim et Chasseur-Froid sont considérées comme étant de « propagation ». Dans ce contexte précis, les hauteurs d'eau à ces endroits sont donc davantage influencées par les écoulements provenant de l'amont plutôt que par les précipitations locales. À l'inverse, d'après la même source et toujours dans les mêmes conditions de prévision, les stations de Sarrebourg et de Waltenheim sont considérées comme étant des stations de « propagation » et « pluie-débit ». Les hauteurs d'eau à ces stations sont alors influencées par les écoulements provenant de l'amont, mais également par les précipitations locales. Chaque station hydrométrique servant à la prévision des crues est située en aval d'autres stations (dont l'emplacement est indiqué en figure 1, et sont listées dans le tableau I), pouvant être hydrométrique (relevant le débit et la hauteur d'eau), représentée par un triangle en figure 1, ou bien météorologique (relevant des données climatiques comme la température et l'humidité de l'air), alors représentée par un losange.

Enfin, chaque station de prévision des crues en France dispose de ses propres seuils d'alerte pour avertir les autorités d'un risque imminent d'inondation. Néanmoins, ces seuils ne sont pas accessibles au public. Dans le cadre de cette étude, et afin de pouvoir calculer certains critères de performance hydrologique, les hauteurs considérées sont $h_{\text{alerte}} \geq 2,4$ m à Sarrebourg, $h_{\text{alerte}} \geq 1,8$ m à Kogenheim, $h_{\text{alerte}} \geq 1,9$ m à Waltenheim et $h_{\text{alerte}} \geq 2,1$ m à Chasseur-Froid (3 % des valeurs de hauteur d'eau les plus élevées sur l'intégralité de la chronique disponible, soit près de 16, 17, 9 et 19 ans respectivement).




Figure 1. Localisation des stations hydrométriques

Station de prévision des crues	Stations hydrométriques à l'amont	Stations météorologiques	Chronique globale disponible
La Sarre à Sarrebourg (SRG)	La Sarre à Hermelange La Sarre blanche à Laneuveville-lès-Lorquin La Sarre rouge à Vasperviller	Nitting	Septembre 2008 – février 2024 (env. 16 ans)
L'III à Kogenheim (KG)	La Fecht à Ostheim L'III à Colmar Le Giessen à Sélestat	Trois-Épis Colmar Sélestat Kogenheim	Janvier 2007 – février 2024 (env. 17 ans)
La Zorn à Waltenheim (WLT)	La Zinsel du sud à Erckartswiller La Zorn à Saverne	Waltenheim-sur-Zorn Phalsbourg	Juillet 2006 – novembre 2015 (env. 9 ans)
L'III à Chasseur-Froid (CF)	L'III à Fegersheim La Bruche à Holtzheim	Entzheim Strasbourg (jardin botanique)	Janvier 2000 - juillet 2019 (env. 19 ans)

Tableau I. Liste et typologie des stations, date et durée des chroniques globales disponibles

1.2. Architectures d'apprentissage automatique

1.2.1. Algorithmes

Trois algorithmes d'apprentissage supervisé différents ont été considérés dans cette étude. Les deux premiers, **RF** et **GB**, sont des algorithmes d'ensemble qui ont émergé d'un premier travail comme étant les plus pertinents dans le cas d'usage présent en comparaison d'autres modèles (**MLP**, **MLR**, **RNN** et **CNN**) [REIMINGER et al., 2024]. Le troisième algorithme, **LSTM**, a été également testé au regard de la littérature scientifique qui mentionne fréquemment son intérêt dans le domaine :

- *random forest* (**RF**) est une méthode d'apprentissage d'ensemble qui consiste à construire une multitude de prédicteurs faibles indépendants (arbres de décision) et à combiner leurs prédictions pour obtenir une prédiction moyenne ;
- *gradient boosting* (**GB**) est une méthode d'apprentissage d'ensemble similaire au **RF**. Leur principale différence réside dans le fait que, pour **GB**, chaque nouveau prédicteur cherche à corriger les erreurs de son prédécesseur en se concentrant davantage sur les cas qu'il a mal interprétés. Les prédicteurs ne sont donc pas indépendants puisqu'ils sont formés sur la base des résultats des prédicteurs précédents ;
- *long short-term memory* (**LSTM**) est un type de réseau de neurones récurrent (**RNN**) conçu pour traiter des données séquentielles, telles que des séries temporelles. Il est constitué de plusieurs couches et utilise la rétropropagation des erreurs, mais a été construit pour éviter les problèmes d'explosion ou disparition du gradient, courant avec les **RNN**. Il diffère des autres réseaux neuronaux tels que les **RNN** classiques par sa capacité à non pas uniquement conserver les informations relatives aux entrées antérieures, mais également les entrées beaucoup plus anciennes, d'où le nom de « long short-term memory ». Cela lui permet, selon la situation, de garder ou non en mémoire les anciens contextes et dépendances d'une entrée donnée par rapport aux entrées précédentes.

Ces différents algorithmes ont été utilisés sous Python (3.12.2) par l'intermédiaire des bibliothèques *Scikit-learn*, *Keras* et *Tensorflow*. Le détail des modèles et fonctions utilisés en lien avec ces bibliothèques est donné ci-dessous :

- *Scikit-learn* (v 1.0.2) : fonctions *RandomForestRegressor* (modèle **RF**), *GradientBoostingRegressor* (modèle **GB**), *MinMaxScaler* (fonction de normalisation), *StandardScaler* (fonction de standardisation) ;
- *Keras* (v 3.0.5) : fonctions *Sequential* et *Model* (utilisés pour construire les réseaux de neurones couche par couche) ;

- *Tensorflow* (v 2.16.0rc0) : fonctions *Dense* et *LSTM* (couche de neurones artificiels et récurrents de type **LSTM**, respectivement, servant à la création des modèles **LSTM**).

1.2.2. Entraînement des modèles

Pour chacune des stations de prévision, le jeu de données est constitué des grandeurs de hauteur d'eau (mm) et de débit (m³/s) relevées sur les stations hydrométriques au pas de temps horaire. Les stations météorologiques relèvent quant à elles au pas de temps horaire l'humidité de l'air (% hydrométrique), la température (°C) et les précipitations (mm/h). La longueur totale de chaque chronique globale (comprise entre 9 et 19 ans selon la disponibilité des données), les dates de début et de fin de chacune, ainsi que la liste des stations hydrométriques et météorologiques par zone d'étude sont détaillées dans le *tableau I*. Près de 80 000 échantillons horaires étaient donc disponibles et utilisés pour la plus courte chronique, et jusqu'à plus du double pour la plus longue. En considérant les différents types de données hydrométriques et météorologiques disponibles et citées précédemment, cela correspond donc à des jeux de données dépassant largement le million. Un résumé des données recueillies (grandeur, unité, lacunes, date de début et date de fin, valeurs minimales, moyennes et maximales) par station est fourni en *annexe A*.

Les algorithmes d'apprentissage automatique nécessitent de définir un jeu de données dit « d'entraînement » sur lequel les algorithmes vont s'ajuster automatiquement, un jeu de données dit de « validation » utilisé pour suivre et confirmer la convergence de l'entraînement des modèles ainsi qu'un jeu de données de « test » servant à évaluer les performances du modèle sur des données qui n'ont jamais servi à son entraînement. Le choix a été fait d'entraîner les algorithmes sur la totalité des chroniques, et non pas seulement des événements de crues, afin d'apprendre aux modèles à prédire l'hydrodynamique globale des stations, incluant crues, mais également étiages, moyennes eaux, etc. Les jeux d'entraînement, de validation et de test ont été répartis de la façon suivante :

- le jeu d'entraînement correspond à 60 % des données ;
- le jeu de validation correspond aux 10 % des données suivantes (dans l'ordre chronologique) ;
- le jeu de test correspond aux 30 % restants des données.

Contrairement à une séparation aléatoire, les ensembles d'entraînement, de validation et de test ont été structurés de manière strictement chronologique, de manière à entraîner les modèles sur les données les plus

anciennes et à tester ceux-ci sur les données les plus récentes dans le but d'évaluer leur capacité à prédire les données futures. Cela signifie que les modèles sont testés exclusivement sur les dernières années de données disponibles, qui n'ont jamais été utilisées pour leur entraînement. Ce choix permet de garantir que les performances des modèles sont évaluées sur des données complètement indépendantes, ce qui réduit le risque de surapprentissage et assure une généralisation fiable aux périodes futures.

Enfin, les jeux de données ont été normalisés pour garantir les meilleures performances avec l'algorithme **GB** et standardisés pour l'algorithme **LSTM** avec l'aide respective des fonctions *MinMaxScaler* et *StandardScaler* issues de la bibliothèque *Scikit-learn*. La normalisation d'un jeu de données permet un rééchantillonnage afin que toutes les données soient comprises entre 0 et 1. La standardisation correspond également à un rééchantillonnage de la donnée à la différence que, dans ce cas de figure, les données sont comprises entre -1 et 1 tout en entraînant une moyenne égale 0 et un écart type de 1. La relation mathématique permettant la normalisation des données est fournie en équation 1 et celle permettant la standardisation en équation 2.

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (\text{Équation 1})$$

$$x' = \frac{x - \mu}{\sigma} \quad (\text{Équation 2})$$

avec x' la valeur rééchantillonnée de la donnée, x la donnée initiale, μ la moyenne de x sur l'ensemble du jeu de données considéré et σ l'écart type de x sur l'ensemble du jeu de données considéré.

Le nombre de données dans chaque chronique globale, la durée de chacune d'entre elles pour les différents jeux de données, d'entraînement, de validation et de test, ainsi que le nombre d'événements de crue par jeu de données sont détaillés en annexe B. Ces données ont été obtenues via *HydroPortail*⁵, une plateforme française rassemblant en libre accès les données hydrologiques au niveau national. Les données météorologiques ont, quant à elles, été collectées via le portail *Données publiques*⁶ mis en place par Météo-France. Plusieurs paramétrisations des modèles ont été testées pour chaque algorithme (**RF**, **GB** et **LSTM**) en faisant varier leurs hyperparamètres (taux d'apprentissage, nombre de couches, etc.) et ce au niveau des quatre stations d'études. Les modèles retenus et dont les résultats sont présentés par la suite sont ceux qui ont obtenu les meilleurs résultats en phase de test (phase de comparaison du modèle avec des données n'ayant jamais servi à son entraînement) pour chacun des algorithmes (**RF**, **GB** et **LSTM**) et chacune des stations considérées (SRG, KG, WLT et CF). Au total, 12 modèles ont donc été retenus (les trois types de modèles appliqués à chacune des stations considérées) et seront mentionnés par la suite en fonction du nom de la zone d'étude et de l'algorithme utilisé (par exemple le modèle nommé « **KG-LSTM** » correspond à l'algorithme **LSTM** appliqué sur la station de Kogenheim). Les hyperparamètres testés pour obtenir les 12 meilleurs modèles sont fournis dans le tableau II, tandis que les hyperparamètres ayant conduit aux meilleures performances des modèles sont fournis dans le tableau III.

⁵ HydroPortail : <https://hydro.eaufrance.fr>

⁶ <https://donneespubliques.meteofrance.fr>

Algorithme	Hyperparamètres testés
GB	n_estimators : 10, 50, 100, 200, 300, 400, 500 max_depth : 4, 6, 8, 10, 12 loss : mean absolute error, mean squared error feature scaling : aucun, normalisation, standardisation
RF	n_estimators : 10, 50, 100, 200, 300, 400, 500 max_depth : 4, 6, 8, 10, 12 loss : mean absolute error, mean squared error feature scaling : aucun, normalisation, standardisation
LSTM	number_layers : 1, 3, 5, 7, 9, 11 neurons_per_layers : Entre 5 et 500 epochs : [5, 50] batch_size : 50, 100, 200, 300 loss : mean absolute error, mean squared error feature scaling : normalisation, standardisation

Tableau II. Hyperparamètres testés pour obtenir les meilleures performances possible

Modèle	Hyperparamètres retenus
SRG-GB	n_estimators : 100, max_depth : 10, loss : mean squared error, feature scaling : normalisation
SRG-RF	n_estimators : 300, max_depth : 8, loss : mean squared error, feature scaling : aucun
SRG-LSTM	number_layers : 5, neurons_per_layers : 150, 75, 12, 6, 1, epochs : 5, batch_size : 200, loss : mean squared error, feature scaling : standardisation
KG-GB	n_estimators : 200, max_depth : 10, loss : mean squared error, feature scaling : normalisation
KG-RF	n_estimators : 300, max_depth : 8, loss : mean squared error, feature scaling : aucun
KG-LSTM	number_layers : 5, neurons_per_layers : 100, 25, 12, 6, 1, epochs : 5, batch_size : 200, loss : mean squared error, feature scaling : standardisation
WLT-GB	n_estimators : 200, max_depth : 10, loss : mean squared error, feature scaling : normalisation
WLT-RF	n_estimators : 300, max_depth : 8, loss : mean squared error, feature scaling : aucun
WLT-LSTM	number_layers : 5, neurons_per_layers : 500, 125, 60, 30, 1, epochs : 5, batch_size : 200, loss : mean squared error, feature scaling : standardisation
CF-GB	n_estimators : 200, max_depth : 10, loss : mean squared error, feature scaling : normalisation
CF-RF	n_estimators : 300, max_depth : 8, loss : mean squared error, feature scaling : aucun
CF-LSTM	number_layers : 5, neurons_per_layers : 500, 125, 60, 30, 15, epochs : 5, batch_size : 200, loss : mean squared error, feature scaling : standardisation

Tableau III. Hyperparamètres retenus ayant conduit aux meilleures performances des modèles

1.3. Critères de performance

Plusieurs critères ont été utilisés pour évaluer et comparer les performances des modèles. Cela inclut notamment des paramètres statistiques généralement utilisés pour comparer les erreurs résiduelles entre les hauteurs d'eau observées et prédites (*MAE*, *MRE*, *RMSE*), mais également des critères de performances plus adaptés au domaine de la prévision des crues (*NSE*, *PI*, *CSI*). Les équations de ces différents critères sont données en annexe C tandis que leurs valeurs cibles sont résumées en annexe D.

Dans le travail précédant cette étude, un nouveau critère de performance appelé « Taux de Décalage d'Alerte » (*TDA*) a été proposé. Cette métrique est un indicateur des performances de détection du seuil d'alerte et fournit une information sur la capacité d'un modèle à prédire en temps voulu un événement donné (par exemple, une hauteur d'eau considérée comme un seuil de crue pour déclencher une alerte), en tenant compte du temps de prévision souhaité par le modèle, ici 24 heures. Les définitions de la version non bornée (*TDA*), ainsi que de la version bornée (*TDA_b*) de ce critère sont rappelées dans les équations 3 et 4 :

$$TDA = 1 - \frac{|\hat{t}_{seuil} - t_{seuil}|}{pp} \quad (\text{Équation 3})$$

$$TDA_b = \begin{cases} 0, & \text{si } TDA < 0 \\ TDA, & \text{si } TDA \geq 0 \end{cases} \quad (\text{Équation 4})$$

avec *TDA_b* et *TDA* les taux de décalage d'alerte borné et non borné, t_{seuil} le moment observé où le seuil d'alerte est atteint, $\hat{t}_{seuil}$ le moment prédit auquel le seuil d'alerte est atteint, et *pp* la période de prévision.

Le *TDA* varie entre $-\infty$ et 1, le *TDA_b* entre 0 et 1. Leur valeur cible est de 1.

2. Résultats et discussion

2.1. Analyse qualitative des modèles

2.1.1. Modèles ensemblistes

Dans l'objectif de reproduire et d'améliorer à l'aide des données supplémentaires (non uniquement restreintes aux hauteurs d'eau) les travaux précédents [REIMINGER et al., 2024], une première partie du travail concernait l'étude des algorithmes **RF** et **GB** qui montraient de bonnes performances sur la station de Kogenheim avec la hauteur d'eau seule. La comparaison des modèles avec les mesures observées par station est présentée en figure 2. Les périodes choisies sont les suivantes et seront conservées par la suite afin de faciliter la comparaison :

- pour Sarrebourg, la période du 14 février 2020 au 21 mars 2020 ;
- pour Kogenheim, la période du 18 janvier 2021 au 19 février 2021 ;

- pour Waltenheim, la période du 24 avril 2013 au 19 juin 2013;
- pour Chasseur-Froid, la période du 4 novembre 2016 au 26 mai 2016.

La figure 2 permet de comparer les hauteurs d'eau réelles à 24 heures avec les hauteurs d'eau prédites aux quatre stations 24 heures à l'avance par les modèles **RF** et **GB** et pour les événements de crue choisis, inclus dans les données du jeu de test (données non utilisées pour l'entraînement des modèles). Le seuil d'alerte est représenté pour chacune des stations à l'aide d'une ligne horizontale grise. Comme le montre cette figure, les modèles **RF** et **GB** semblent capables de reproduire globalement les fluctuations des niveaux d'eau lors des crues. Cependant, en examinant de plus près les résultats, il apparaît qu'un décalage temporel plus ou moins grand existe entre les prédictions et les mesures, particulièrement visible sur les montées des niveaux d'eau et des prédictions, et au niveau du croisement avec le seuil d'alerte. Les alertes fournies par les modèles sont en retard par rapport à l'objectif initial de prévision à 24 heures, parfois rattrapé sur la décrue. Ce retard n'est pas dû à l'absence de données sur les précipitations, hypothèse donnée dans le travail précédent, car ces données météorologiques furent considérées dans le présent travail. Cela suggère que des données complémentaires doivent être considérées, ou qu'il s'agit là

d'une limite éventuelle de ces modèles. La figure 2 (B) montre qu'à Kogenheim, l'allure de la courbe est très satisfaisante. Les figures 2 (A), (C) et (D) montrent quant à elles des surestimations, particulièrement sur les valeurs extrêmes avec le modèle **GB**. Les figures 2 (A) et (D) présentent du bruit, et les valeurs prédites par les deux algorithmes sont instables. Cela peut être la conséquence du fait que **RF** et **GB** ne sont pas des algorithmes normalement conçus pour traiter des données séquentielles.

2.1.2. Modèles à réseaux neuronaux de type LSTM

Dans l'objectif de réaliser une preuve de concept de l'utilisation de modèles neuronaux de type **LSTM** remplissant les objectifs de ce travail, l'étude a ensuite principalement porté sur cet algorithme. La comparaison de ce modèle avec les mesures observées par station est présentée en figure 3. Les périodes temporelles représentées sont les mêmes que précédemment afin de faciliter d'éventuelles comparaisons.

La figure 3 permet de comparer les hauteurs d'eau réelles avec les hauteurs d'eau prédites aux quatre stations 24 heures à l'avance par le modèle **LSTM** et pour les événements de crue choisis, inclus dans les données du jeu de test. Comme le montre cette figure, **LSTM** est plus adapté au traitement des séries temporelles, car les courbes ont une allure beaucoup plus lisse. Le modèle **LSTM** semble capable de reproduire assez fidèlement les variations des niveaux d'eau lors des crues. Le




Figure 2. Comparaison entre les niveaux d'eau observés (ligne noire) et prédits par RF et GB (respectivement lignes en jaune et bleu) à 24 heures sur les quatre stations d'étude en fonction du temps pour des périodes de crue définies précédemment dans l'ensemble de test




Figure 3. Comparaison entre les niveaux d'eau observés (ligne noire) et prédits par LSTM (ligne en vert) à 24 heures sur les quatre stations d'étude en fonction du temps pour les périodes de crue définies précédemment dans l'ensemble de test

décalage temporel observé précédemment avec RF et GB est moindre, voire quasi inexistant sur les premiers pics de crues dépassant le seuil critique. Les alertes fournies par les modèles LSTM sont moins en retard par rapport aux modèles RF et GB. La figure 3 (B) montre qu'à Kogenheim, l'allure de la courbe est très proche des mesures. Les figures 3 (A), (C) et (D) présentent moins de surestimations que précédemment. Les figures 3 (A) et (D) présentent moins de bruit, et les valeurs prédites

par les deux algorithmes sont plus stables. On notera que les résultats qualitatifs les moins satisfaisants avec cet algorithme sont observés à Chasseur-Froid, où les courbes restent instables.

2.2. Comparaison des modèles

2.2.1 Performances

Le tableau IV présente les valeurs des RMSE, MAE, MRE, PI, NSE_1 , NSE_2 , NSE_3 et TDAb moyens obtenues

Modèle	RMSE (mm)	MAE (mm)	MRE	PI	NSE_1	NSE_2	NSE_3	TDAb	CSI	FN
SRG-GB	369	251	0,12	0,18	0,25	0,11	-0,24	0,33	0,70	2
SRG-RF	367	242	0,11	0,20	0,28	0,12	-0,29	0,14	0,69	5
SRG-LSTM	191	142	0,07	0,73	0,58	0,75	0,82	0,52	0,93	0
KG-GB	85	57	0,04	0,68	0,79	0,91	0,94	0,61	0,86	0
KG-RF	89	59	0,04	0,66	0,78	0,90	0,93	0,61	0,80	0
KG-LSTM	71	50	0,03	0,79	0,81	0,95	0,98	0,68	0,92	0
WLT-GB	424	284	0,20	0,39	0,27	0,12	-0,28	0,30	0,48	0
WLT-RF	392	245	0,17	0,47	0,37	0,26	-0,06	0,28	0,60	1
WLT-LSTM	263	201	0,15	0,73	0,48	0,64	0,71	0,29	1,00	0
CF-GB	122	82	0,04	0,10	0,38	0,43	0,40	0,27	0,73	1
CF-RF	119	76	0,04	0,15	0,43	0,46	0,40	0,31	0,82	2
CF-LSTM	121	83	0,04	0,16	0,39	0,50	0,51	0,44	0,94	0

Tableau IV. RMSE, MAE, MRE, PI, NSE_1 , NSE_2 , NSE_3 et TDAb moyens obtenus sur les différents épisodes de crues du jeu de test par station et par modèle

sur l'ensemble des épisodes de crues du jeu de test par station et par modèle, ainsi que le *CSI* et *FN* (nombre de faux négatifs) sur l'ensemble du jeu de test. Ces résultats renforcent les observations précédentes. En effet, avec un *RMSE* compris entre 71 et 89 mm (soit moins de 10 cm), un *MAE* compris entre 50 et 59 mm, un *MRE* compris entre 3 et 4 %, un *PI* compris entre 0,66 et 0,79, des *NSE₁*, *NSE₂* et *NSE₃* compris entre 0,78 et 0,98, un *TDAb* compris entre 0,61 et 0,68, un *CSI* compris entre 0,80 et 0,92 et un nombre de faux négatifs de 0, les modèles à Kogenheim sont les meilleurs prédicteurs. Malgré ces résultats très proches, le modèle **KG-LSTM** reste celui qui a obtenu les meilleurs résultats avec notamment un critère de persistance *PI* de 0,79.

Une différence bien plus marquée existe entre les modèles ensemblistes (**RF** et **GB**) et les modèles **LSTM** pour les stations Sarrebourg et Waltenheim, avec une nette amélioration des métriques avec ce dernier modèle. À Sarrebourg et Waltenheim avec **LSTM**, le *RMSE* est respectivement de 191 et 263 mm (soit moins de 30 cm), le *MAE* est de 142 et 201 mm, le *MRE* est de 7 et 15 %, le *PI* est de 0,73 pour les deux stations, les *NSE₁*, *NSE₂* et *NSE₃* sont de 0,58, 0,75, 0,82 pour Sarrebourg et de 0,48, 0,64, et 0,71 pour Waltenheim, et le *TDAb* est de 0,52 pour Sarrebourg et 0,29 pour Waltenheim. Pour **LSTM** à Sarrebourg et Waltenheim, le *CSI* est respectivement de 0,93 et 1, avec un nombre de faux négatifs de 0. Ces résultats sont bien supérieurs à ceux obtenus par les modèles ensemblistes, avec notamment un critère de persistance *PI* de l'ordre de 0,7 pour le **LSTM** au niveau des deux stations, contre des valeurs de l'ordre de 0,2 à Sarrebourg et de 0,4 à Waltenheim obtenu avec les modèles **GB** et **RF**.

Enfin, pour la station Chasseur-Froid, les métriques *RMSE*, *MAE*, *MRE*, *PI*, *NSE₁*, *NSE₂*, *NSE₃* et *CSI* sont du même ordre de grandeur pour les trois modèles et seul le nombre de faux négatifs et le *TDAb* diffèrent, ce dernier étant légèrement meilleur avec le modèle **LSTM**. Au niveau de cette station, tous les modèles obtiennent des valeurs de persistance supérieures à 0, sans pour autant être particulièrement performants.

D'après les résultats obtenus, les moins bons modèles à Sarrebourg, Waltenheim et Kogenheim sont les modèles ensemblistes. Un *NSE₂* compris entre 0,5 et 0,7 permet de qualifier un modèle de « satisfaisant », de « bon » entre 0,7 et 0,8 et « très bon » au-delà [MORIASI et al., 2015]. Considérant ces plages de validité, les modèles satisfaisants sont alors : **WLT-LSTM**; les modèles bons sont : **SRG-LSTM**; et les modèles très bons sont : **KG-RF**, **KG-GB**, **KG-LSTM**. En outre, on notera que tous ces modèles ont obtenu des critères de persistance *PI* de l'ordre de 0,7, avec un léger avantage aux modèles **LSTM** ayant quasiment atteint 0,8 à Kogenheim.

2.2.2. Diagramme de différences critiques

L'évaluation basée uniquement sur les critères de performance ne constitue pas l'approche la plus intuitive pour identifier le ou les meilleurs modèles, car les résultats peuvent parfois présenter des tendances contradictoires. Bien que certains modèles se démarquent clairement, il est difficile de comparer directement les résultats présentés dans le *tableau IV* pour classer les modèles en fonction de leur score global sur tous les critères, par exemple en distinguant les modèles ensemblistes pour Sarrebourg, Kogenheim, Waltenheim, et Chasseur-Froid, car les critères n'évoluent pas de la même manière, ni vers le même optimum, et il est difficile




Figure 4. Diagrammes de différence critique classant les performances des modèles par station sur l'ensemble des critères (global)

de savoir dans quelle mesure deux valeurs sont statistiquement différentes. Le classement présenté en figure 4 correspond à des diagrammes de différences critiques obtenus en utilisant la méthode de FAWAZ et al. [2019]. Celle-ci permet de classer différents modèles en fonction de leur performance sur un ensemble de critères considérés.

La figure 4 confirme les observations réalisées en section 2.2.1. Le modèle **LSTM** est significativement plus performant que les modèles **RF** et **GB** pour les stations de Sarrebourg, Kogenheim et Waltenheim. Le diagramme de différences critiques permet de différencier les modèles **RF** et **GB**, notamment pour Kogenheim et Waltenheim, où **RF** apparaît comme étant plus performant que **GB**. Pour Sarrebourg, ces deux modèles sont très proches, comme l'indique la barre horizontale reliant les deux modèles (différence non significative entre les modèles). Pour Chasseur-Froid, les modèles **GB** et **LSTM** sont proches, et c'est **RF** qui se distingue comme étant le meilleur. On notera que malgré ce résultat, le modèle **CF-RF**, n'est pas qualifiable de satisfaisant d'après les résultats quantitatifs décrits en section précédente.

3. Discussion

Les résultats précédents ont été obtenus sur des zones situées dans le même bassin versant du Rhin, qui partagent un climat continental, un relief modéré et une absence d'influence littorale. Ce travail pourrait sans doute être transposable à d'autres zones similaires. Cependant, dans des régions où le relief est plus prononcé, où la mer exerce une influence notable, ou qui possèdent un climat très différent de celui de l'Alsace, les résultats pourraient varier et nécessiter des ajustements. Au-delà de ces caractéristiques influençant les écoulements, les modèles doivent être recalibrés pour chaque nouvelle station étudiée.

L'utilisation de l'intelligence artificielle pour la prévision des crues demande toutefois une certaine prudence. Par exemple, à la station de Chasseur-Froid, même un algorithme avancé comme **LSTM** peut n'obtenir que des performances limitées en raison de la dynamique hydrologique unique à chaque station. La hauteur d'eau à Kogenheim, par exemple, dépend principalement des débits observés en amont, avec peu d'influence des précipitations. Cette particularité rend l'entraînement des modèles plus facile, même avec des modèles simples comme *random forest* (**RF**) ou *gradient boosting* (**GB**). En revanche, les stations de Waltenheim et Sarrebourg sont à la fois des stations de propagation et

de pluie-débit, donc également influencées par la pluie. Pour améliorer les modèles, il pourrait être pertinent d'intégrer des données sur l'état du sol, telles que la perméabilité et le niveau des nappes phréatiques, afin de mieux représenter les processus d'évaporation, d'évapotranspiration, de ruissellement et d'infiltration.

Le cas de Chasseur-Froid est particulièrement complexe : située en aval du centre-ville de Strasbourg, cette station subit peu de variations de niveau d'eau, car elle est fortement régulée par des vannes et écluses pour la navigation de plaisance. Cette régulation atténue les liens naturels entre niveau d'eau et débit, le flux d'eau étant partiellement dévié vers un autre bras de rivière, rendant les modèles moins performants pour cette station.

Bien que les algorithmes **RF** et **GB** offrent des résultats satisfaisants pour la prévision des crues et la prédiction globale des niveaux d'eau, cette étude montre que le modèle **LSTM**, conçu pour les séries temporelles, produit de meilleurs résultats, aussi bien pour les stations de propagation (Kogenheim) que pour celles à dynamique plus complexe (Sarrebourg et Waltenheim). Les modèles **LSTM** présentent de faibles marges d'erreur, entre 3 % et 15 %, ce qui est excellent. En matière de prévision des crues, les coefficients de Nash-Sutcliffe obtenus, allant de 0,6 à 0,95, se comparent favorablement aux valeurs qu'il est possible d'obtenir de modèles hydrologiques traditionnels comme **SWAT** [KATEB et al., 2019] ou **LARSIM** [ISHIKAWA et al., 2021].

Enfin, pour les modèles **LSTM** des trois premières stations (à l'exclusion de Chasseur-Froid), les valeurs de *PI* sont comprises entre 0,73 et 0,79 et les *CSI* dépassent 0,91. Ce modèle est le seul à ne faire aucun faux négatif, quelle que soit la station étudiée dans le cadre de ces travaux et c'est également celui qui obtient les meilleurs résultats en termes de *TDAb*, soulignant le fait qu'il est le modèle le plus à même à donner une alerte en temps voulu (ni trop tôt, ni trop tard). Cela atteste de l'excellente performance de cet algorithme pour la prévision des crues.

Conclusion

RF, **GB** et **LSTM**, trois algorithmes d'apprentissage automatiques, ont été considérés dans ce travail et entraînés sur quatre stations de prévisions des crues françaises situées dans le Grand Est, résultants en 12 modèles de prédiction des hauteurs d'eau à 24 heures. Les résultats obtenus par ces algorithmes ont été présentés, comparés et discutés.

Les résultats obtenus montrent que les crues peuvent être prédites 24 heures à l'avance de manière précise et fiable, en se basant uniquement sur des données publiques issues de stations hydrométriques et météorologiques à un pas de temps horaire. L'utilisation d'un modèle spécialiste (**LSTM**) des données séquentielles a permis d'améliorer grandement les résultats de modèles plus simples (**RF** et **GB**). Les modèles **LSTM** ont donné des coefficients d'efficacité de Nash-Sutcliffe

(**NSE**) atteignant 0,95, des indices de persistance (**PI**) d'environ 0,75 et des indices de succès critique (**CSI**) d'environ 0,9 et allant jusqu'à 1. Enfin, ces modèles n'ont donné aucun faux négatif, quelle que soit la station de prévision considérée, contrairement aux modèles ensemblistes **RF** et **GB**. Ce travail confirme la pertinence et la légitimité de l'utilisation des modèles d'intelligence artificielle, et plus spécifiquement les réseaux de neurones de type **LSTM**, pour la prévision des crues en France.

Bibliographie

AMNATSAN S., YOSHIKAWA S., KANAE S. (2018) : « Improved forecasting of extreme monthly reservoir inflow using an analogue-based forecasting method: A case study of the Sirikit Dam in Thailand » *Water*; 10(11) : 1614.

BYARUHANGA N., KIBIRIGE D., GOKOOL S., MKHONTA G. (2024) : « Evolution of flood prediction and forecasting models for flood early warning systems: A scoping review ». *Water*; 16(13) : 1763.

CALVIN K., DASGUPTA D., KRINNER G., MUKHERJI A., THORNE P.W., TRISOS C. et al., (2023) : *IPCC, 2023: Climate Change 2023: Synthesis Report. Contribution of Working Groups I, II and III to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change [Core Writing Team, H. Lee and J. Romero (eds.)]. IPCC, Geneva, Switzerland. [First]. Intergovernmental Panel on Climate Change (IPCC). DOI : 10.59327/IPCC/AR6-9789291691647*

CCR (2021) : *Étude sur l'efficacité des plans de prévention des risques d'inondation sur le coût des dommages assurés (PPRI)*. Disponible en ligne : <https://www.ccr.fr/-/ccr-etude-ppri>

DA SILVA L.B.L., ALENCAR M.H., DE ALMEIDA A.T. (2022) : « A novel spatiotemporal multi-attribute method for assessing flood risks in urban spaces under climate change and demographic scenarios ». *Sustainable Cities and Society*; 76: 103501.

DAS M., GHOSH S.K., CHOWDARY V.M., SAI KRISHNAVENI A., SHARMA R.K. (2016) : « A probabilistic nonlinear model for forecasting daily water level in reservoir ». *Water Resources Management*; 30(9) : 3107-22.

FAWAZ H.I., FORESTIER G., WEBER J., IDOUMGHAR L., MULLER P.-A. (2019) : « Deep learning for time series classification: a review ». *Data Mining and Knowledge Discovery*; 33(2) : 917-63.

GAUCH M., KRATZERT F., KLOTZ D., NEARING G., LIN J., HOCHREITER S. (2021) : « Rainfall-runoff prediction at multiple timescales with a single Long Short-Term Memory network ». *Hydrology and Earth System Sciences*; 25(4) : 2045-62.

GAUME E., GOSSET R. (2003) : « Over-parameterisation, a major obstacle to the use of artificial neural networks in hydrology? ». *Hydrology and Earth System Sciences Discussion*; 7(5) : 693-706.

HAKIM D. K., GERNOWO R., NIRWANSYAH A. W. (2024) : « Flood prediction with time series data mining: Systematic review ». *Natural Hazards Research*; 4(2) : 194-220.

HOCHREITER S., SCHMIDHUBER J. (1997) : « Long short-term memory ». *Neural Computation*; 9(8) : 1735-80.

HSU K., GUPTA H.V., SOROOSHIAN S. (1995) : « Artificial neural network modeling of the rainfall-runoff process ». *Water Resources Research*; 31(10) : 2517-30.

HU Y., YAN L., HANG T., FENG J. (2020) : « Stream-flow forecasting of small rivers based on LSTM ». *arXiv*. DOI : 10.48550/arXiv.2001.05681

IBRAHIM K.S.M.H., HUANG Y.F., AHMED A.N., KOO C.H., EL-SHAFIE A. (2022) : « A review of the hybrid artificial intelligence and optimization modelling of hydrological stream-flow forecasting ». *Alexandria Engineering Journal*; 61(1) : 279-303.

ISHIKAWA M., HAAG I., KRUMM J., TELTSCHER K., LORKE A. (2021) : « The effect of stream shading on the inflow characteristics in a downstream reservoir ». *River Research and Applications*; 37(7) : 943-54.

JINGMING HOU, NIE ZHOU, GUANGZHAO CHEN, MIANSONG HUANG, GUANGBI BAI (2021) : « Rapid forecasting of urban flood inundation using multiple machine learning models ». *Natural Hazards*; 108(2) : 2335-56.

KALOOP M.R., EL-DIASTY M., HU J.W. (2017) : « Real-time prediction of water level change using adaptive neuro-fuzzy inference system ». *Geomatics, Natural Hazards and Risk*; 8(2) : 1320-32.

KATEB Z., BOUCHELKIA H., BENMANSOUR A., BELARBI F. (2019) : « Hydrological modeling using the SWAT model based on two types of data from the watershed of Beni Haroun dam, Algeria ». *Journal of Water and Land Development*; 43(1) : 76-89.

KHAI W.J., ALRAIH M., AHMED A.N., FAI C.M., EL-SHAFIE Ahmed, EL-SHAFIE Amr (2019) : « Daily forecasting of dam water levels using machine learning ». *International Journal of Civil Engineering and Technology (IJCET)*; 10(6) : 314-23.

KIM C., KIM C.-S. (2021) : « Analysis of AI-based techniques for forecasting water level according to rainfall ». *Tropical Cyclone Research and Review*; 10(4) : 223-8.

- KRATZERT F., KLOTZ D., BRENNER C., SCHULZ K., HERRNEGGER M. (2018) : « Rainfall-runoff modelling using Long Short-Term Memory (LSTM) networks ». *Hydrology and Earth System Sciences*; 22(11) : 6005-22.
- KUN XIE, KAN OZBAY, YUAN ZHU, HONG YANG (2017) : « Evacuation zone modeling under climate change: A data-driven method ». *Journal of Infrastructure Systems*; 23(4) : 1-9.
- LEG L.-E. (2019) : « Das Wasserhaushaltsmodell LARSIM – Modellgrundlagen und Anwendungsbeispiele ». Disponible en ligne : <https://www.hydrology.uni-freiburg.de/publika/FSH-Bd11-Bremicker.pdf>
- LIU D., JIANG W., MU L., WANG S. (2020) : « Streamflow prediction using deep learning neural network: Case study of Yangtze River ». *IEEE Access*; 8 : 90069-86.
- MOHR S., EHRET U., KUNZ M., LUDWIG P., CALDAS-ALVAREZ A., DANIELL J.E., et al. (2023) : « A multi-disciplinary analysis of the exceptional flood event of July 2021 in central Europe. Part 1: Event description and analysis ». *Natural Hazards and Earth System Sciences*; 23(2) : 525-51.
- MORIASI D.N., GITAU M.W., PAI N. (2015) : « Hydrologic and water quality models: performance measures and evaluation criteria ». *Transactions of the ASABE*; 58(6) : 1763-85.
- MOSAVI A., OZTURK P., CHAU K. (2018) : « Flood prediction using machine learning models: Literature review ». *Water*; 10(11) : 1536.
- MUNAWAR H.S., HAMMAD A.W.A., WALLER S.T. (2022) : « Remote sensing methods for flood prediction: A review ». *Sensors*; 22(3) : 960.
- NEVO S., MORIN E., GERZI ROSENTHAL A., METZGER A., BARSHAI C., WEITZNER D., et al. (2022) : « Flood forecasting with machine learning models in an operational framework ». *Hydrology and Earth System Sciences*; 26(15) : 4013-32.
- NUR ADLI ZAKARIA M., ABDUL MALEK M., ZOLKEPLI M., NAJAH AHMED A. (2021) : « Application of artificial intelligence algorithms for hourly river level forecast: A case study of Muda River, Malaysia ». *Alexandria Engineering Journal*; 60(4) : 4015-28.
- PIRI J., KAHKHA M.R.R. (2016) : « Prediction of water level fluctuations of chahnimeh reservoirs in zabol using ANN, ANFIS and cuckoo optimization algorithm ». *Iranian Journal of Health, Safety & Environment*; 4(2) : 706-15.
- REIMINGER N., JURADO X., SAUNIER L., MAURER L., REIMINGER E., WEBER L., et al. (2024) : « Évaluation des performances de l'intelligence artificielle et de l'apprentissage automatique pour la prévision des crues : étude de cas du bassin versant de l'Ill ». *Techniques Sciences Méthodes*; 11 : 53-71.
- SAPITANG M., RIDWAN W.M., FAIZAL KUSHIAR K., NAJAH AHMED A., EL-SHAFIE A. (2020) : « Machine learning application in reservoir water level forecasting for sustainable hydro-power generation strategy ». *Sustainability*; 12(15) : 6121.
- SHAMIM M.A., HASSAN M., AHMAD S., ZEESHAN M. (2016) : « A comparison of artificial neural networks (ANN) and local linear regression (LLR) techniques for predicting monthly reservoir levels ». *KSCE Journal of Civil Engineering*; 20(2) : 971-7.
- TIBERI-WADIER A.-L., GOUTAL N., RICCI S., SERGENT P., VIATGÉ J., MONTEIL C., BOUTTIER F. (2021) : « Étude de sensibilité globale comparée des modèles hydrologiques GRP et MORDOR-TS ». *LHB Hydrosience Journal*; 107(1) : 1-11.
- ÜNEŞ F., DEMIRCI M., TAŞAR B., KAYA Y., VARÇIN H. (2019) : « Estimating dam reservoir level fluctuations using data-driven techniques ». *Polish Journal of Environmental Studies*; 28(5) : 3451-62.
- VIATGÉ J., PINNA T., FICCHI A., PERRIN C., DORCHIES D., GARANDEAU L., TILMANT F. (2019) : « Vers une plus grande flexibilité temporelle du modèle opérationnel de prévision des crues GRP ». *La Houille Blanche*; 105(2) : 72-80.
- WEE W. J., ZAINI N. B., AHMED A.N., EL-SHAFIE A. (2021) : « A review of models for water level forecasting based on machine learning ». *Earth Science Informatics*; 14(2) : 1707-28.
- ZAJI A.H., BONAKDARI H., GHARABAGHI B. (2018) : « Reservoir water level forecasting using group method of data handling ». *Acta Geophysica*; 66(4) : 717-30.
- ZEYNODDIN M., BONAKDARI H., EBTEHAJ I., AZARI A., GHARABAGHI B. (2020) : « A generalized linear stochastic model for lake level prediction ». *Science of the Total Environment*; 723 : 138015.
- ZHANG X., LIU P., ZHAO Y., DENG C., LI Z., XIONG M. (2018) : « Error correction-based forecasting of reservoir water levels: Improving accuracy over multiple lead times ». *Environmental Modelling & Software*; 104 : 27-39.
- ZHENG J., HUANG G. (2023) : « Towards flood risk reduction: Commonalities and differences between urban flood resilience and risk based on a case study in the Pearl River Delta ». *International Journal of Disaster Risk Reduction*; 86 : 103568.
- ZHU S., HRNJICA B., PTAK M., CHOIŃSKI A., SIVAKUMAR B. (2020) : « Forecasting of water level in multiple temperate lakes using machine learning models ». *Journal of Hydrology*; 585 : 124819.

Annexe A

Résumé des données hydrométriques et climatiques de l'étude

Zone	Grandeur	Unité	Nombre de lacunes	Début de la chronique	Fin de la chronique	Minimum	Maximum	Moyenne
Grandeurs hydrométriques								
SRG	Débit Sarrebourg	m³/s	1	1/1/00 0:00	1/2/24 0:00	0	57,863	3
	Débit Hermelange	m³/s	16	14/9/08 8:00	1/2/24 0:00	0	26,9147	1
	Débit Laneuveville-lès-Lorquin	m³/s	4	1/1/00 0:00	1/2/24 0:00	0,0741	10,6	0,916
	Débit Vasperviller	m³/s	73	1/1/00 0:00	1/2/24 0:00	0,328	12,5	1,30
	Hauteur Sarrebourg	mm	0	1/1/00 0:00	1/2/24 0:00	992	3292	1378
	Hauteur Hermelange	mm	0	14/9/08 8:00	1/2/24 0:00	278	1900	538
	Hauteur Laneuveville-lès-Lorquin	mm	0	1/1/00 0:00	1/2/24 0:00	226	1522	437
	Hauteur Vasperviller	mm	0	1/1/00 0:00	1/2/24 0:00	137	1596	363
Grandeurs météorologiques								
	Pluie Nitting	mm/h	290	9/5/07 10:00	31/1/24 3:00	0	35	0,10
	Température Nitting	°C	86	9/5/07 10:00	31/1/24 3:00	-19,2	37,7	10,3
Grandeurs hydrométriques								
KG	Débit Colmar	m³/s	1	1/1/00 0:00	1/2/24 0:00	0,838	282	19,5
	Débit Sélestat	m³/s	0	1/1/07 0:00	1/2/24 0:00	0	65,7	2,69
	Débit Ostheim	m³/s	0	1/1/00 0:00	1/2/24 0:00	0,247	101	6,67
	Débit Kogenheim	m³/s	0	9/9/06 23:00	1/2/24 0:00	6,94	282	35,7
	Hauteur Colmar	mm	0	1/1/00 0:00	1/2/24 0:00	907	4850	1456
	Hauteur Sélestat	mm	0	1/1/07 0:00	1/2/24 0:00	-93	1999	610
	Hauteur Ostheim	mm	0	1/1/00 0:00	1/2/24 0:00	316	3718	767
	Hauteur Kogenheim	mm	0	9/9/06 12:00	1/2/24 0:00	321	2566	889
Grandeurs météorologiques								
	Pluie Sélestat	mm/h	77	1/1/00 0:00	31/1/24 3:00	0	34	0,070
	Température Sélestat	°C	64	1/1/00 0:00	31/1/24 3:00	-16,9	38,8	11,4
	Humidité Sélestat	%	66	1/1/00 0:00	31/1/24 3:00	14	100	77
	Pluie Trois-Épis	mm/h	40	1/1/00 0:00	31/1/24 3:00	0	37	0,090
	Température Trois-Épis	°C	78	1/1/00 0:00	31/1/24 3:00	-16,9	35,3	9,9
	Pluie Colmar	mm/h	75	1/1/00 0:00	30/1/24 18:00	0	32	0,064
	Température Colmar	°C	53	1/1/00 0:00	30/1/24 18:00	-19,3	38,7	11,4
	Humidité Colmar	%	93	1/1/00 0:00	30/1/24 18:00	6	100	75
Grandeurs hydrométriques								
WLT	Débit Eckartswiller	m³/s	1	5/7/06 14:00	1/2/24 0:00	0	23,5	0,878
	Débit Saverne	m³/s	0	1/1/00 0:00	1/2/24 0:00	0	30,0	1,83
	Débit Waltenheim	m³/s	0	1/1/00 0:00	1/2/24 0:00	0,411	119	5,44
	Hauteur Eckartswiller	mm	0	5/7/06 14:00	1/2/24 0:00	-4	3323	290
	Hauteur Saverne	mm	0	1/1/00 0:00	1/2/24 0:00	19	1857	272
	Hauteur Waltenheim	mm	0	1/1/00 0:00	1/2/24 0:00	253	3081	660
	Grandeurs météorologiques							
	Pluie Phalsbourg	mm/h	134	1/1/00 0:00	31/1/24 3:00	0	54,2	0,095
	Température Phalsbourg	°C	119	1/1/00 0:00	31/1/24 3:00	-17	37,7	10,4
	Humidité Phalsbourg	%	124	1/1/00 0:00	19/11/15 12:00	16	100	79
	Pluie Waltenheim	mm/h	136	8/9/04 7:00	31/1/24 3:00	0	41	0
	Température Waltenheim	°C	25	8/9/04 9:00	31/1/24 3:00	-14,6	37,6	11,1
	Humidité Waltenheim	%	33	8/9/04 9:00	31/1/24 3:00	14	100	76
Grandeurs hydrométriques								
CF	Débit Holtzheim	m³/s	0	1/1/00 0:00	1/2/24 0:00	0	177	7,58
	Débit Chasseur-Froid	m³/s	2	1/1/00 0:00	1/2/24 0:00	25,0	200	65,7
	Débit Fegersheim	m³/s	0	1/1/00 0:00	1/2/24 0:00	21,1	66,6	45,2
	Hauteur Holtzheim	mm	0	1/1/00 0:00	1/2/24 0:00	105	3584	632
	Hauteur Chasseur-Froid	mm	0	1/1/00 0:00	1/2/24 0:00	1096	3009	1656
	Hauteur Fegersheim	mm	0	1/1/00 0:00	1/2/24 0:00	623	1595	1255
	Grandeurs météorologiques							
	Pluie Entzheim	mm/h	11	1/1/00 0:00	31/1/24 3:00	0	41	0,072
	Température Entzheim	°C	21	1/1/00 0:00	31/1/24 3:00	-17,7	38,8	11,5
	Humidité Entzheim	%	21	1/1/00 0:00	31/1/24 3:00	13	100	76
	Pluie Botanique	mm/h	171	1/1/00 0:00	31/1/24 3:00	0,0	35	0,078
	Température Botanique	°C	57	1/1/00 0:00	31/1/24 3:00	-13,1	39,5	12,0
	Humidité Botanique	%	66	1/1/00 0:00	16/7/19 9:00	15	99	74

Annexe B

Découpage des jeux de données pour chacune des zones d'étude

Zone	Modèles	Jeu de données	Longueur (années)	Nombre d'échantillons	Nombre d'épisodes de crue
SRG	RF, GB	train	10,8	94 346	46
		test	4,6	40 434	16
	LSTM	train	9,2	80 811	53
		validation	1,5	13 468	19
		test	4,6	40 405	22
KG	RF, GB	train	12	104 794	23
		test	5,1	44 913	13
	LSTM	train	10,2	89 767	24
		validation	1,7	14 961	2
		test	5,1	44 883	11
WLT	RF, GB	train	6,6	57 505	25
		test	2,8	24 646	12
	LSTM	train	5,6	49 233	27
		validation	0,9	8 206	10
		test	2,8	24 616	22
CF	RF, GB	train	13,7	119 874	45
		test	5,9	51 376	22
	LSTM	train	11,7	102 693	41
		validation	2	17 115	14
		test	5,9	51 346	33

Annexe C

Définitions des critères de performances de l'étude

- Erreur moyenne absolue (*MAE*, *mean absolute error*) et sa version relative :

$$MAE = \frac{1}{n} \sum_{i=1}^n |O_i - P_i| \quad (A1)$$

$$MRE = \frac{1}{n} \sum_{i=1}^n rAE_i = \frac{1}{n} \sum_{i=1}^n \frac{|O_i - P_i|}{O_i} \quad (A2)$$

avec *MAE* l'erreur moyenne absolue, *rAE_i* l'erreur relative pour la *i*^{ème} prédiction, *MRE* l'erreur moyenne absolue relative à la moyenne des observations, *n* le nombre de paires d'observations et de prédiction dans le jeu de données, *O_i* l'*i*^{ème} observation et *P_i* l'*i*^{ème} prédiction.

- Erreur quadratique moyenne (*RMSE*, *root mean squared error*) et sa version relative :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (O_i - P_i)^2} \quad (A3)$$

avec *RMSE* l'erreur quadratique moyenne, *n* le nombre de paires d'observations et de prédiction dans le jeu de données, *O_i* l'*i*^{ème} observation et *P_i* l'*i*^{ème} prédiction.

- Coefficient de Nash-Sutcliffe (*NSE*, *Nash-Sutcliffe efficiency coefficient*) et sa généralisation :

$$NSE = 1 - \frac{\sum_{i=1}^n (O_i - P_i)^2}{\sum_{i=1}^n (O_i - \bar{O})^2} \quad (A4)$$

$$NSE_j = 1 - \frac{\sum_{i=1}^n |O_i - P_i|^j}{\sum_{i=1}^n |O_i - \bar{O}|^j} \quad (A5)$$

avec NSE le coefficient de Nash-Sutcliffe, NSE_j le coefficient de Nash-Sutcliffe généralisé à $j^{\text{ème}}$ degré, n le nombre de paires d'observations et de prédiction dans le jeu de données, O_i l' $i^{\text{ème}}$ observation et P_i l' $i^{\text{ème}}$ prédiction.

- **Indice de persistance (PI, persistence index) :**

$$PI = 1 - \frac{\sum_{i=1}^n (O_i - P_i)^2}{\sum_{i=1}^n (O_i - O_{i-1})^2} \quad (A6)$$

avec PI l'indice de persistance, n le nombre de paires d'observations et de prédiction dans le jeu de données, O_i l' $i^{\text{ème}}$ observation, O_{i-1} la $i-1^{\text{ème}}$ observation et P_i l' $i^{\text{ème}}$ prédiction.

L'équation précédente est l'équation générale de l'indice de persistance. Dans le cas spécifique de la prévision des crues 24 heures à l'avance, cas rencontré dans le présent travail, l'équation A6 devient l'équation A7, équation qui a été utilisée dans cet article :

$$PI = 1 - \frac{\sum_{i=1}^n (O_{i,t+24h} - P_{i,t+24h})^2}{\sum_{i=1}^n (O_{i,t+24h} - O_{i,t})^2} \quad (A7)$$

Avec PI l'indice de persistance, n le nombre de paires d'observations et de prédiction dans le jeu de données, $O_{i,t+24h}$ l' $i^{\text{ème}}$ observation à $t+24h$, $P_{i,t+24h}$ l' $i^{\text{ème}}$ prédiction du modèle à $t+24h$ et $O_{i,t}$ l' $i^{\text{ème}}$ observation à t .

- **Indice critique de succès (CSI, critical success index) :**

$$CSI = \frac{TP}{TP + FP + FN} \quad (A8)$$

avec CSI l'indice critique de succès, TP le nombre de vrais positifs, FP le nombre de faux positifs et FN le nombre de faux négatifs.

Annexe D

Résumé des valeurs cibles des critères de performances de l'étude

Critère	Type	Valeurs		
		Minimale	Satisfaisante	Idéale
MAE	Absolu	$+\infty$	–	0
MRE	Relatif	$+\infty$	–	0
RMSE	Absolu	$+\infty$	–	0
NSE_1	Relatif	$-\infty$	≥ 0	1
NSE_2 (ou NSE)	Relatif	$-\infty$	≥ 0	1
NSE_3	Relatif	$-\infty$	≥ 0	1
PI	Relatif	$-\infty$	≥ 0	1
CSI	Relatif	0	–	1
TDA	Relatif	$-\infty$	0	1
TDA _b	Relatif	0	–	1