



Prédiction et reconstruction de données hydrauliques par apprentissage machine

Bastien Nony

► To cite this version:

Bastien Nony. Prédiction et reconstruction de données hydrauliques par apprentissage machine. [Technical Report] CECI, Université de Toulouse, CNRS, CERFACS, Toulouse, France - TR-CMGC-19-TR-CMGC-20-145. 2020. <hal-04738467>

HAL Id: hal-04738467

<https://cnrs.hal.science/hal-04738467v1>

Submitted on 15 Oct 2024

HAL is a multi-disciplinary open access archive for the deposit and dissemination of scientific research documents, whether they are published or not. The documents may come from teaching and research institutions in France or abroad, or from public or private research centers.

L'archive ouverte pluridisciplinaire **HAL**, est destinée au dépôt et à la diffusion de documents scientifiques de niveau recherche, publiés ou non, émanant des établissements d'enseignement et de recherche français ou étrangers, des laboratoires publics ou privés.



HAL Authorization



Prédiction et reconstruction de données hydrauliques par apprentissage machine

Bastien NONY

supervisé par

CORENTIN LAPEYRE et SOPHIE RICCI

Juin 2019

Table des matières

1	Cadre de stage	3
1.1	Présentation du CERFACS	4
2	Introduction	6
3	Présentation des modèles statistiques utilisés	8
3.1	Modèle linéaire	8
3.1.1	Estimation des poids du modèle	9
3.2	régression Ridge	9
3.2.1	Utilité de ces modèles	10
3.3	ϵ -SVR	10
3.3.1	Introduction et généralités sur les SVM	10
3.3.2	Procédure ϵ -SVR	12
3.4	Gradient boosting	13
3.5	Perceptron multi-couches (MLP)	14
3.6	Structure d'un réseau de neurones	15
3.7	Fonctions d'activation	16
3.8	Optimisation des poids du modèle	17
4	Segmentation d'un jeu de données	17
5	Choix des critères de performance	19
5.1	Persistance	20
5.2	Efficience	21
6	Analyse de données	22
6.1	Choix de sélection des données	25

6.2	Analyse de quelques crues	26
7	Prédiction des temps d'écoulement entre stations	26
7.1	Estimateur de corrélation croisée	27
7.2	Estimateur de la différence de pics de crues	29
7.3	Agrégation des deux estimateurs	29
7.4	Estimation du temps de propagation pour quelques stations	30
8	Modèle de prédiction à 4h	30
8.1	Présentation du cas d'étude	30
8.1.1	Cartographie des stations d'intérêt et commentaires	31
8.2	Base d'entraînement des modèles	32
8.3	Modèle baseline SPC	32
8.4	Résultats des modèles statistiques	33
8.5	Commentaires	34
9	Modèle de prédiction à 6h	35
9.1	Présentation du cas d'étude	35
9.1.1	Cartographie des stations d'intérêt et commentaires	35
9.2	Modèle baseline SPC	36
9.3	Premiers modèles pour toutes les méthodes	37
9.4	Feature engineering	38
9.4.1	Commentaires sur les erreurs commises	39
10	Conclusion	39
11	Annexe	45

Remerciements

Je tiens tout d’abord à remercier Nicolas Cazard, Corentin Lapeyre et Sophie Ricci pour leur encadrement, leur soutien et leurs conseils de rédaction.

Merci également aux membres du Cerfacs que j’ai eu le plaisir de côtoyer pendant ce stage. Enfin, j’ai une pensée pour tous les gens qui me sont proches et qui ont su me rendre ces années d’études plus que mémorables.

1 Cadre de stage

J’effectue mon stage de fin d’études au Centre européen de recherche et de formation avancée en calcul scientifique (C.E.R.F.A.C.S.). Je suis intégré au groupe Helios [Hel] dont l’objectif est la prise en main des techniques d’apprentissage machine pour la résolution de problèmes physiques. Le groupe Helios vient en partie appuyer des projets déjà existants du CERFACS. Stagiaires, ingénieurs, doctorants, post-doctorants et chercheurs travaillent ensemble au sein de ce groupe d’étude créé en septembre 2018.

Le projet sur lequel je travaille est né d’une initiative du service de prévision des crues de Toulouse (S.P.C.) qui travaille à la surveillance des cours d’eau et à la prévention des risques d’inondation dans la région Occitanie [SPC]. Le SPC est sous la tutelle de la Direction régionale de l’environnement, de l’aménagement et du logement (DREAL) Occitanie. La DREAL est un service déconcentré du ministère de la Transition écologique et solidaire (MTES) et du ministère de la Cohésion des Territoires (MTC). Elle est placée sous l’autorité du préfet de région [DRE].

L’équipe de recherche Modélisation du Climat du Cerfacs et de son changement global du CERFACS s’intéresse régulièrement au cas Garonne. Une multitude de projets - et ce depuis plusieurs années - tentent de modéliser, de simuler et de prédire au mieux les dynamiques

d'écoulement. A l'occasion du projet d'initiation à la recherche de quatrième année à l'INSA, Alban Gossard et moi-même avons déjà travaillé sur la mise en place de modèles réduits et sur une quantification d'incertitudes pour la reconstruction de données hydrologiques sur un tronçon de la Garonne en aval de Toulouse.

L'équipe Helios a également mis en place une série de compétitions de reconstruction et de prédiction de hauteur d'eau sur ce même tronçon. L'idée est de pouvoir se familiariser, de s'entraîner à la manipulation de modèles statistiques et d'en tester de nouveaux sur deux grands jeux de données : le premier, simulé, issu du code de calcul TELEMAC-MASCARET [GGH91], le second composé de données in-situ. C'est en partie par ce biais que j'ai commencé à manipuler divers algorithmes dits de machine learning : modèles linéaires, machines à vecteurs supports, gradient boosting, réseaux de neurones multicouches, etc.

Ce stage s'inscrit dans cette continuité comme travail pluridisciplinaire. Par le biais de ce projet, le Cerfacs apporte une expertise supplémentaire au service de prévision de crues. L'objectif général aura été d'initier et d'accompagner ce service à l'utilisation des techniques de machine learning.

1.1 Présentation du CERFACS

Le Cerfacs est un centre de recherche fondamentale et appliquée, spécialisé dans la modélisation et la simulation numérique. Par ses moyens et savoir-faire en calcul haute performance, le Cerfacs traite des grands problèmes scientifiques et techniques de recherche publique et industrielle.

Les équipes du Cerfacs réunissent des physiciens, des mathématiciens appliqués, des analystes numériques, des informaticiens qui conçoivent et développent des méthodes et solutions logicielles innovantes répondant aux besoins des secteurs de l'aéronautique, du spatial, du climat, de l'énergie et de l'environnement.

Impliqué dans des projets d'envergure nationale et internationale, le Cerfacs travaille en forte

interaction avec ses sept associés : Airbus Group, Cnes, EDF, Météo France, Onera, Safran et Total. Il a en outre noué des partenariats avec le CNRS (Unité de recherche associée), l'Irit (laboratoire commun), le CEA et l'Inria (accords de coopération).

Voici quelques dates clés :

- 1987 : Création du Groupement scientifique Cerfacs autour de 11 membres : Aérospatiale, Cnes, CNRS, INPT, Inria, Insa, Matra-Marconi Space, Direction de la Météorologie nationale, Onera, Région Midi-Pyrénées.
- 1988 : Le Cerfacs se transforme en Groupement d'intérêt public
- 1996 : Le Cerfacs devient société civile, autour de quatre structures associées : Aérospatiale, devenue EADS puis Airbus Group, Cnes, Météo France et EDF.
- 1999 : Création de l'Unité de recherche associée Cerfacs-CNRS, Sciences de l'Univers au Cerfacs (Ura 1875) Convention de collaboration avec le CEA dans le domaine des méthodes de calcul avancé
- 2004 : Safran nouvel associé du Cerfacs
- 2006 : Onera nouvel associé du Cerfacs
- 2008 : Total nouvel associé du Cerfacs
- 2009 : Création d'un laboratoire commun Inria/Cerfacs
- 2013 : Accord de coopération Inria/Cerf
- 2015 : Le dixième calculateur installé au Cerfacs depuis 1996 entre au 388^e rang du top500 avec une puissance crête de 242 Tflop/s.

Les principales missions du Cerfacs sont :

- Développer des recherches scientifiques et techniques visant l'amélioration des méthodes de calcul avancé, incluant une meilleure prise en compte des processus physiques concernés, et la mise au point d'algorithmes performants pour les nouvelles architectures de calculateurs.
- Permettre l'accès, soit en propre, soit en mode partagé, aux calculateurs d'architecture nouvelle susceptibles d'apporter un gain significatif de performances.
- Transférer ces connaissances scientifiques et méthodes techniques, pour application, vers les grands secteurs industriels.
- Former des personnels hautement qualifiés et offrir une formation avancée pour les secteurs et domaines d'application retenus.

2 Introduction

Un mécanisme précis de surveillance en temps réel de la situation fluviale offre davantage de temps aux autorités pour gérer les crues et éviter les catastrophes. Un tel système permet de protéger à la fois infrastructures et individus à proximité de zones à risque. Certains tronçons de la Garonne sont souvent sujets à une montée des eaux; la situation pouvant s'avérer dangereuse en cas de réaction tardive. A Toulouse, côté rive droite, on pensera notamment aux quais de la Daurade régulièrement inondés. Au niveau du quai de l'exil républicain espagnol, des portes étanches séparent les rues habitées de la Garonne par temps de crue. Si ces mécanismes permettent une protection efficace de certains lieux, d'autres sont en revanche plus sensibles : c'est notamment le cas de l'île du Ramier. L'un des principaux objectifs de ce stage est de fournir un système de prédiction suffisamment robuste pour de longues échelles de temps. Des prédictions à échéances de 6h puis, idéalement, de 8h offrirait un temps de réaction suffisamment souple pour, en cas de danger, veiller à la

bonne évacuation du site. Si cette situation peut aujourd’hui paraître extrême, il ne faut pas sous-estimer la capacité de la Garonne à surprendre par ses débordements aussi rapides que spectaculaires. La Garonne a vu monter son niveau d’eau à plus de 4m30 en certains endroits, forçant entre autres l’évacuation de l’île du Ramier [cru]. Les évolutions brutales de hauteur d’eau limitent les échéances de prévision. Une estimation de la hauteur d’eau au niveau de Toulouse devient complexe au delà d’une échéance de 6h. Le problème nécessite une combinaison de données : mesures des hauteurs et débits d’eau au niveau des affluents de la Garonne, données pluviométriques, etc. En effet, des phénomènes brusques comme par exemple d’intenses intempéries sur des échelles de temps assez courtes peuvent rendre vains les essais de prévisions en temps long.

Plusieurs tentatives de prédiction de hauteur d’eau en contexte fluvial ont déjà été étudiées dans la littérature. Campolo [CSA03] propose une prédiction de hauteurs d’eau sur la rivière Arno en Italie jusqu’à une échéance maximum de 6h. Wu [WCL08] implémentent une certaine forme de machine à vecteurs supports (Distributed SVR) pour une prévision de hauteur d’eau fluviale. Enfin, Maier [MD00] recourent quarante-trois travaux de recherche travaillant à la prédiction de hauteurs et débits d’eau dans différents contextes à partir de modèles statistiques.

Dans l’ensemble de ces travaux, l’usage de réseaux de neurones de type Multilayer perceptron a été presque toujours systématique. Nous verrons que notre contexte ne nous le permet pas forcément. Le manque de données d’entraînement ne nous permet que difficilement un entraînement raisonnable des réseaux de neurones conventionnels. Parmi la multitude d’outils de prédiction statistiques, le plus adéquat (ie. celui pour lequel nous obtiendrons les résultats les plus probants) sera un algorithme de type Gradient Boosting optimisé pour l’occasion.

Nous allons introduire les différents outils statistiques utilisés dans ce projet. Nous présenterons notre jeu de données et les façons de l’adapter aux algorithmes statistiques.

Enfin nous présenterons deux cas de prédiction au niveau de Toulouse. Le premier, plus simple, nous servira de cas-jouet pour comprendre les enjeux d'un tel problème et les attentes du service de prévision des crues. Le second, plus complexe, nous mènera vers une comparaison intéressante des résultats obtenus par différents algorithmes prédictifs.

3 Présentation des modèles statistiques utilisés

Considérons le problème suivant : Nous disposons d'un jeu de données à N individus $(x_i, y_i)_{i=1, \dots, N}$, où les $x_i \in \mathbf{R}^n$ sont des quantités connues et $y_i \in \mathbf{R}$ la quantité inconnue du problème.

Ce problème de prédiction de variables quantitatives peut être résolu par une approche statistique. Des modèles de régression sont connus dans la littérature. Nous présentons dans cette partie ceux qui sont utilisés dans ce projet.

3.1 Modèle linéaire

Présentons quelques généralités sur le modèle linéaire multivariable adapté à un problème de régression de variables quantitatives. L'inconnue y_i est supposée combinaison linéaire des variables d'entrée x_i , auquel s'ajoute un bruit aléatoire [Sap06] :

$$\forall i = 1, \dots, n \quad y_i = \sum_{i=1}^n x_i \theta_i + \epsilon_i$$

où les θ_i sont les coefficients du modèles, a priori inconnus et à estimer. Les $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ modélisent le bruit pour chaque variable d'observation (σ^2 étant a priori inconnu).

Remarque : les bruits ϵ_i sont supposés indépendants deux à deux.

On note la formulation matricielle du problème :

$$Y = X\beta + \epsilon, \text{ avec } \beta = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$$

3.1.1 Estimation des poids du modèle

L'estimation des poids du modèle demande de considérer une fonction de perte associée. Généralement on cherche à minimiser la norme 2 des erreurs (cas considéré par l'algorithme de régression linéaire implémenté sous sklearn et que nous utilisons dans ce projet [PVG⁺11]), ainsi :

$$\hat{\beta} = \operatorname{argmin}_{\beta} \|X\beta - Y\|_2$$

Dans le cas où la matrice $X'X$ est diagonalisable, on obtient comme vecteur de coefficients : $\hat{\beta} = (X'X)^{-1}X'Y$ Et donc l'estimateur des individus devient :

$$\hat{Y} = X(X'X)^{-1}X'Y$$

3.2 régression Ridge

La régression Ridge (ou régression de Tikhonov) consiste en une régression linéaire régularisée. Le problème d'optimisation des paramètres du modèle est augmenté d'un terme de pénalisation en norme L2 :

$$\hat{\beta} = \operatorname{argmin}_{\beta} \|Y - X\beta\|_2^2 + \lambda \|\beta\|_2^2$$

Cela fournit un contrôle sur la variance du modèle statistique en introduisant un terme de régularisation donnant de plus faibles valeurs aux coefficients.

3.2.1 Utilité de ces modèles

La régression linéaire, avec ou sans régularisation ridge, est simple d'implémentation. Elle permet de capter les dépendances linéaires entre les variables d'entrée du modèle et les valeurs à prédire. Elle servira de modèle de référence dans notre problème de prédiction. Les résultats de modèles plus complexes pourront être comparés à ce modèle plus basique et visuel.

3.3 ϵ -SVR

L'algorithme ϵ -SVR est un cas particulier de machine à vecteurs supports (en anglais : support vector machine, SVM) appliqué aux problèmes de régression. Avant d'en présenter les spécificités, énonçons quelques généralités sur les machines à vecteurs supports.

3.3.1 Introduction et généralités sur les SVM

Initialement développées pour répondre à des problèmes de discrimination (ie. prévision d'une variable binaire), les SVM reposent sur la recherche d'un hyperplan dit de marge optimale. Cet hyperplan sépare l'espace des individus en deux sous-espaces, correspondant à une dichotomie de l'ensemble d'étude (Figure 1). L'objectif est alors de donner une capacité de généralisation la plus grande possible à notre classifieur (ou à notre fonction de discrimination).

La conception des machines à vecteurs supports est issue des travaux en théorie de l'apprentissage de Cortes [CV95].

Le principe fondateur des algorithmes de type SVM repose sur la recherche du meilleur hyperplan discriminant (ce que précédemment nous avons appelé "hyperplan de marge op-




Figure 1: Les variables binaires sont discriminées par la frontière de décision (en noir)
Source : <http://wikistat.fr>

timal"). Ainsi, la solution cherchée est celle relative à un problème d'optimisation sous contraintes. Le nombre de contraintes actives (appelées vecteurs supports) vient contrôler la complexité du modèle statistique. De plus, pour gérer les phénomènes non-linéaires, on peut avoir recours à l'utilisation de fonctions noyaux (en anglais : kernels) agissant sur les données et sur leurs dépendances mutuelles.

Ces types d'algorithmes peuvent être très efficaces et peuvent être utilisés dans divers cas d'études (classification, régression, clustering, etc.) mais sont cependant très vite pénalisés par un nombre trop important de vecteurs supports, réduisant leur efficacité tant du point

de vue de la qualité des résultats fournis qu'au niveau du temps de calcul.

3.3.2 Procédure ϵ -SVR

Dans ce projet nous utilisons la procédure de régression de type ϵ -SVR implémentée dans la librairie python scikit-learn [PVG⁺11, LIB04]. Considérons le jeu d'échantillons $((x_1, z_1), \dots, (x_n, z_n))$. Le problème d'optimisation à résoudre est le suivant :

$$\begin{aligned} \min_{a,b,\alpha_i,\alpha_i^*} \quad & \frac{1}{2} \|a\|_2^2 + C \sum_{i=1}^n \alpha_i + C \sum_{i=1}^n \alpha_i^* \\ \text{s.c. :} \quad & \begin{cases} a' \cdot \phi(x_i) + b - z_i \leq \epsilon + \alpha_i \\ z_i - a' \cdot \phi(x_i) - b \leq \epsilon + \alpha_i^* \\ \alpha_i, \alpha_i^* \geq 0, i = 1, \dots, n \end{cases} \end{aligned}$$

Intuitivement ce problème de minimisation nous invite à trouver les coefficients a et b d'une prédiction linéaire (ici $a \cdot \phi(x) + b$) sur les entrées x_i transformées par le noyau ϕ . Les sorties y_i sont soit dans un tube de rayon ϵ autour de la prédiction linéaire $a \cdot \phi(x) + b$, soit en dehors du tube. Dans le second cas elles influent sur la partie pénalisante du problème de minimisation.

La formulation précédente du problème ϵ -SVR est appelée forme primale. Dans les faits, on résout la forme duale que nous donnons ci-après :

$$\begin{aligned} \min_{\beta_i, \beta_i^*} \quad & \frac{1}{2} (\beta - \beta^*)' K (\beta - \beta^*) + \epsilon \sum_{i=1}^n (\beta_i + \beta_i^*) + \sum_{i=1}^n z_i (\beta_i - \beta_i^*) \\ \text{s.c. :} \quad & \begin{cases} \epsilon' (\beta - \beta^*) = 0 \\ 0 \leq \beta_i, \beta_i^* \leq C, i = 1, \dots, n \end{cases} \\ \text{avec :} \quad & K_{i,j} = K(x_i, x_j) = \phi(x_i)' \cdot \phi(x_j) \end{aligned}$$

Ainsi, par la résolution du problème dual, l'estimateur ϵ -SVR est donné par :

$$\hat{f}(x) = \sum_{i=1}^n (\beta_i^* - \beta_i) K(x_i, x) + b$$

3.4 Gradient boosting

Dans l'idée, un gradient boosting est une suite d'estimateurs élémentaires successifs où chaque élément corrige l'erreur commise par le précédent. Ainsi, le schéma de construction est le suivant :

- On choisit un certain modèle
- On l'entraîne sur des données
- On entraîne un second modèle à corriger les résidus du premier
- On répète l'étape précédente récursivement

Les machines gradient boosting visent à obtenir, au sein d'une certaine classe de fonctions, celle minimisant le risque empirique sur l'échantillon d'observations.

Considérons Ψ une fonction de coût, $\{(x_1, y_1), \dots, (x_N, y_N)\}$ une série d'observations, F la fonction théorique à approcher.

La méthode de gradient boosting introduite par Friedman [Fri01] répond au problème d'optimisation suivant :

$$\hat{F} = \operatorname{argmin} \mathbf{E}_{x,y} [\Psi(y, F(x))]$$

où $\hat{F}$ est l'estimateur de F de la forme :

$$\hat{F}(x) = \sum_{i=1}^M \gamma_i h_i(x) + K$$

M un hyperparamètre choisi par l'utilisateur représentant le nombre de fonctions d'apprentissage de base (base learner functions) notées h .

Friedman [Fri01] propose un algorithme itératif pour résoudre ce problème passant par une méthode de meilleure descente de gradient (steepest gradient descent).

Tout d'abord une première approximation de F est donnée par :

$$F_0(x) = \operatorname{argmin}_{\gamma} \sum_{i=1}^N \Psi(y_i, \gamma) \text{ avec } \Psi \text{ une fonction de coût}$$

Le chemin itératif est ensuite défini par :

$$F_m(x) = F_{m-1}(x) + \operatorname{argmin}_{h_m \in \mathcal{H}} \sum_{i=1}^N \Psi(y_i, F_{m-1}(x_i) + \gamma_m h_m(x_i))$$

C'est un problème d'optimisation difficile à résoudre. Une solution apportée est de minimiser pas à pas en passant par une descente de gradient. Ainsi :

$$F_m(x) = F_{m-1}(x) - \gamma_m \sum_{i=1}^N \nabla F_{m-1} \Psi(y_i, F_{m-1}(x_i))$$

où

$$\gamma_m = \operatorname{argmin}_{\gamma} \sum_{i=1}^N \Psi(y_i, F_{m-1}(x_i) - \gamma \nabla F_{m-1} \Psi(y_i, F_{m-1}(x_i)) - \gamma \nabla F_{m-1} \Psi(y_i, F_{m-1}(x_i)))$$

3.5 Perceptron multi-couches (MLP)

Nous ne présentons dans cette partie qu'une vue d'ensemble des réseaux de neurones. Les estimateurs par réseaux de neurones n'étant qu'accessoires dans ce projet, la compréhension précise de leur fonctionnement n'y est pas nécessaire.

Un réseau de neurones artificiels est une fonction approximante basée sur une structure en graphe, dont la construction initiale est inspirée des structures neuronales biologiques. Ils

constituent une classe à part entière d’algorithmes statistiques.

Composés d’une multitude de fonctions de base (d’opérations mathématiques simples, telles que des combinaisons linéaires) combinées successivement les unes aux autres, ils disposent d’une grande capacité d’adaptation. Ceci leur permet de gérer des situations où le nombre de degrés de liberté du problème met en péril d’autres algorithmes statistiques moins adaptatifs.

Remarque : nous ne parlerons ici que de réseaux de neurones de type perceptrons multicouches car ils sont à la fois simples, fondamentaux dans la théorie des réseaux de neurones, et adaptés à notre problématique de prévision des crues.

3.6 Structure d’un réseau de neurones

Un réseau de neurones est un graphe reliant des noeuds entre eux. Une information est propagée à partir de l’entrée du réseau vers la sortie et transite par les noeuds du réseau où elle subit des transformations successives. La valeur d’entrée est ainsi quantifiée, modifiée dans le réseau pour finalement donner une certaine valeur de sortie. Mathématiquement, un réseau de neurones peut être vu comme une composition de fonctions simples agrégées les unes aux autres pour venir former un estimateur universel. Le graphe suivant (Figure 2) représente un réseau de neurones de type multilayer perceptron (MLP) à trois couches. La valeur d’entrée rentre dans le modèle par la gauche. Ici on $(x_1, x_2) \in \mathbf{R}^2$ comme entrées du modèle. Deux premiers calculs combinent les entrées (x_1, x_2) : $h_1(x_1, x_2)$ et $h_2(x_1, x_2)$. Trois calculs sont ensuite effectués en chaque noeud de la couche intermédiaire sur les sorties de la couche d’entrée $f_1(h_1(x_1, x_2), h_2(x_1, x_2))$, $f_2(h_1(x_1, x_2), h_2(x_1, x_2))$ et $f_3(h_1(x_1, x_2), h_2(x_1, x_2))$, puis deux calculs sont à nouveau réalisés sur la couche de sortie, reprenant cette fois-ci comme variables d’entrée les sorties de la couche intermédiaire, ie : $g_1(f_1, f_2, f_3)$ et $g_2(f_1, f_2, f_3)$.

La structure même des réseaux de neurones leur permet de s’adapter à diverses problématiques : régression, classification, etc. Tout l’enjeu est alors de bien définir la structure du




Figure 2: Réseau de neurones de type MLP à 3 couches

réseau de neurones (ie. le nombre de couches, le nombre de noeuds en chaque couche, etc.) ainsi que de trouver les bons paramètres du modèles.

3.7 Fonctions d'activation

Les fonctions dénotées dans notre exemple par f , g et h sont appelées fonctions d'activation. De l'utilisation que nous faisons des réseaux de neurones, ces fonctions sont prédéfinies par l'utilisateur. Plusieurs fonctions sont possibles et leur choix dépend principalement de la configuration du problème. Ici nous en présentons quelques unes des plus utilisées (Figure 3). Pour mieux comprendre la façon dont se propage l'information, prenons le cas simple où la fonction d'activation des noeuds est la fonction identité, ie. $f = g = h = Id$. Au noeud h_1 , les entrées x_1 et x_2 sont transformées en $h_1(x_1, x_2) = a_1^{h_1} \times x_1 + a_2^{h_1} \times x_2$, où $(a_1^{h_1}, a_2^{h_1})$ sont les coefficients à optimiser, propres au noyau h_1 . De même pour le noeud h_2 , on obtient : $h_2(x_1, x_2) = a_1^{h_2} \times x_1 + a_2^{h_2} \times x_2$. L'information se propage ensuite à la deuxième couche. Au noeud $f_1(h_1, h_2) = a_1^{f_1} \times h_1 + a_2^{f_1} \times h_2$. Le processus itère jusqu'à la sortie du réseau.

Activation function	Equation	Example	1D Graph
Unit step (Heaviside)	$\phi(z) = \begin{cases} 0, & z < 0, \\ 0.5, & z = 0, \\ 1, & z > 0, \end{cases}$	Perceptron variant	
Sign (Signum)	$\phi(z) = \begin{cases} -1, & z < 0, \\ 0, & z = 0, \\ 1, & z > 0, \end{cases}$	Perceptron variant	
Linear	$\phi(z) = z$	Adaline, linear regression	
Piece-wise linear	$\phi(z) = \begin{cases} 1, & z \geq \frac{1}{2}, \\ z + \frac{1}{2}, & -\frac{1}{2} < z < \frac{1}{2}, \\ 0, & z \leq -\frac{1}{2}, \end{cases}$	Support vector machine	
Logistic (sigmoid)	$\phi(z) = \frac{1}{1 + e^{-z}}$	Logistic regression, Multi-layer NN	
Hyperbolic tangent	$\phi(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	Multi-layer NN	

Figure 3: Quelques fonctions d'activation régulièrement utilisées dans la construction réseaux de neurones (source : An introduction to artificial neural network and its detailed implementation in Python and Excel)

3.8 Optimisation des poids du modèle

Les coefficients a_i (appelés poids du modèle) sont optimisés par des méthodes d'optimisation classiques de type descente de gradient. C'est pourquoi les fonctions d'activations (les f_i , g_i et h_i) ont, dans la pratique, des contraintes particulières de différentiabilité.

4 Segmentation d'un jeu de données

De façon générale, un algorithme statistique nécessite deux grandes étapes. La première, la phase d'entraînement, optimise le modèle pour l'adapter aux données qui lui sont fournies. La seconde, la phase de validation, rend compte de l'efficacité du modèle optimisé.

Pour ce faire, on scinde le jeu de données initial en deux sous-ensembles. Les données du jeu d'entraînement sont celles que verra le modèle statistique et sur lequel il règlera la valeur

de ses coefficients. Le jeu de validation tente d'apporter une évaluation non biaisée de la qualité d'estimation du modèle entraîné pour limiter le problème d'overfitting. C'est grâce à l'entraînement de validation que l'on ajuste les hyperparamètres d'un modèle (par exemple le coefficient de régularisation de Tykhonov pour un modèle linéaire).

Cependant il existe une nouvelle fois une limite à la segmentation en deux sous-ensembles. L'ajustement répétitif d'hyperparamètres d'un modèle statistique permet d'ajuster le modèle entraîné par rapport aux échantillons de validation, ie. que du jeu de données de validation on tire une information que l'on réinsère dans le modèle pour en améliorer davantage les performances. Ainsi, l'ensemble de validation ne se contente pas de valider le modèle mais l'affecte (certes de façon indirecte) dans sa structure même. C'est pour cette raison que, souvent, un jeu de données se retrouve séparé en trois sous-ensemble : la partie d'entraînement pour l'optimisation du modèle, la validation pour l'ajustement des hyperparamètres et l'échantillon de test pour fournir une estimation finale de ses performances. En termes de proportions, le jeu d'entraînement est généralement le plus fourni en données. Une pratique courante serait par exemple de fournir 60% des données au jeu d'entraînement, 20% à l'échantillon de validation et les 20% restants seraient consacrés à la phase de test. Cependant ces pratiques peuvent être différentes en fonction du cas de figure.

Remarquons que valider directement un modèle sur son jeu d'entraînement serait un choix peu judicieux pour des raisons d'overfitting. En effet, si un modèle dispose d'une grande capacité d'adaptation, il pourra très bien s'adapter au jeu d'entraînement, peut-être même un peu trop. L'étape de validation donnerait un très bon résultat sans rendre compte des zones de sur-apprentissage. Le modèle a aussi bien appris de l'échantillon d'entraînement les règles généralisables que le bruit lié à ces observations spécifiques. C'est justement par la comparaison des résultats entre deux échantillons de données que l'on peut vérifier la

capacité d'un modèle à généraliser sans sur-apprendre.

Remarque : l'avancée de nos travaux nous a mené à ne considérer que des échantillons d'entraînement et de validation. Le jeu de données de test a pour le moment été oublié par manque de données. Les prochaines étapes du stage (dont nous reparlerons en conclusion) permettront d'offrir plus de données dont une partie sera laissée comme échantillon de test.

5 Choix des critères de performance

Avant de construire tout modèle statistique, il est important de définir leurs critères de performance, ie. de choisir des indices quantitatifs de comparaison. Ce choix est primordial car il peut fortement impacter les résultats, la structure même du modèle et la technique d'optimisation choisie pour en retirer les meilleurs paramètres. De manière générale, de nombreux critères de performance peuvent être choisis en amont d'un modèle. De grandes catégories comme la vitesse d'entraînement d'un modèle, les coûts mémoire et temporel de calcul de ses prédictions peuvent être autant de critères raisonnables.

Dans un cas comme le nôtre - c'est à dire la prédiction de crues - il n'est entre autres pas raisonnable de minimiser la valeur moyenne des erreurs sur l'année. En effet, le modèle risquerait de se concentrer sur les prédictions par beau temps tout en négligeant les erreurs en temps de crues qui ne représentent que des phénomènes ponctuels très courts sur l'année. La durée cumulée des périodes de crues ne représente au maximum qu'une semaine sur toute une année.

Plusieurs indices de performance servent de base de comparaison de nos modèles et nous aident dans la sélection du modèle a priori le plus efficace dans notre cas de figure.

En termes de prévisions de crues, un indice important mais hautement sensible est l'information

de pire prédiction, ie. la plus mauvaise prédiction faite sur les données mises à notre disposition. Quoique très parlant il pose deux problèmes majeurs. D'un point de vue de la physique il se peut qu'une crue tout à fait exceptionnelle vienne le modifier du tout au tout. D'un point de vue mathématique, par sa non-différentiabilité, la norme $\|\cdot\|_\infty$ ne permet pas de répondre aux problèmes d'optimisation fonctionnelle.

Ainsi, trois premiers indices de comparaison sont utiles pour répondre à notre problématique. Tout d'abord la moyenne des erreurs $\|\cdot\|_2$ de prédiction est un passage obligé tant elle apporte d'informations sur la nature des résultats d'un modèle. Elle a l'avantage d'être différentiable deux fois et sert principalement de fonction de coût (en anglais : loss function) pour l'optimisation de nos modèles statistiques. Cependant, sa valeur peut fausser l'interprétation sur l'efficacité d'un modèle statistique. Pour reprendre l'exemple ci-dessus, un modèle prévoyant parfaitement la hauteur d'eau en période de non crue - et ce au détriment des prédictions en temps de crue - pourrait apparaître comme meilleur qu'un second modèle qui lui prévoirait mieux les crues mais manquant de précision en périodes de faibles débits.

Comme indices de performance supplémentaires, nous utiliserons la valeur de quantile à 90% et l'erreur maximum commise sur les prédictions de hauteur d'eau. Ils apportent une information plus visuelle de l'efficacité de nos modèles.

5.1 Persistance

La persistance est un critère permettant de comparer l'écart de prévision à l'échéance de Δt avec l'accroissement du débit observé pendant Δt .

$$\text{Persistance CP}\Delta t \text{ (\%)} = 100 \times \left(1 - \frac{\sum (Q_{\text{prévu}}(t + \Delta t) - Q_{\text{Obs}}(t + \Delta t))^2}{\sum (Q_{\text{Obs}}(t) - Q_{\text{Obs}}(t + \Delta t))^2}\right)$$

où

$Q_{Obs}(t)$ est le débit observé à l'instant t

$Q_{prévu}(t + \Delta t)$ est le débit prévu à l'instant $t + \Delta t$ (avec une échéance de prévision de Δt)

Un critère de persistance de 100% traduit une prévision parfaite.

Un critère de persistance de 0% traduit le fait que la courbe des débits prévus est une simple translation de Δt de l'hydrogramme observé. Un tel modèle persistant est dit aussi "inerte":

le futur est égal au présent : $Q_{Prvu}(t + \Delta t) = Q_{obs}(t)$

L'avantage de ce critère est qu'il intègre le délai de prévision.

5.2 Efficience

L'efficience s'exprime comme le critère de NASH; le débit calculé étant remplacé par le débit prévu.

$$\text{EFFICIENCE}(\%) = 100 \times \left(1 - \frac{\sum (Q_{obs}(t) - Q_{prévu}(t))^2}{\sum (Q_{obs}(t) - \overline{Q}_{obs})^2}\right)$$

où :

$Q_{obs}(t)$ est le débit observé à l'instant t

$Q_{prévu}(t)$ est le débit calculé à l'instant t

$\overline{Q}_{obs}$ est la moyenne arithmétique des débits observés

Ce critère vaut 100% pour une prévision parfaite.

Pour le service de prévision des crues, lorsque le critère d'efficience est supérieur à 95% il est considéré comme très bon. En deçà de 80%, il est considéré comme mauvais. Il peut même prendre des valeurs négatives en cas de mauvaise prévision.

6 Analyse de données

Le temps est un facteur clé à considérer dans de nombreux problèmes de prédiction. La base de données sur laquelle nous nous appuyons dans ce projet regroupe l'information de hauteur d'eau mesurée en 22 stations réparties sur une partie du parc fluvial de la région Sud-Ouest en amont de Toulouse.

La nature des données nous mène à considérer l'évolution de séries temporelles multidimensionnelles (chaque dimension étant respectivement la série temporelle relative à chaque station).

Les relevés hydrographiques peuvent remonter à 1988 pour les stations les plus anciennes. La fréquence de mesure a quant à elle changé au cours du temps ; elle a été d'une mesure par heure en jusqu'en 2012 à une mesure tous les quarts d'heure depuis.

Si la base de données fournit des informations en hauteur d'eau, dans un contexte d'écoulement hydraulique il peut être préférable de travailler plutôt sur des débits (grandeur extensive) pour des questions de linéarité. En effet, si deux débits issus se somment à la jointure entre deux tronçons d'eau ce n'est pas du tout le cas en termes de hauteurs d'eau. La possibilité nous est laissée de convertir hauteurs d'eau en débits (et vice versa) par le biais de courbes de tarage (Figure 4).

La nature des données et l'entraînement de modèles statistiques requièrent un travail amont de préparation des relevés. Cette étape est appelée preprocessing.

Plusieurs questions sont à se poser lorsque l'on travaille sur des jeux de données d'observation, et plus particulièrement sur des séries temporelles. Présentons un découpage du travail de preprocessing [Aga15]:

- Nettoyage des données : Les données qui servent de base d'entraînement à nos modèles statistiques peuvent être incomplètes (absence de valeurs), bruitées (contenant des erreurs ou des valeurs anormales) ou incohérentes. Dans notre cas, il existe des périodes




Figure 4: Courbes de tarage pour six stations d'observation situées en amont de Toulouse

où les mesures contiennent des valeurs aberrantes. Peuvent être en cause des travaux sur les stations de relevés, un étalonnage des outils de mesure. D'autres données peuvent ne pas être incluses simplement parce qu'elles n'étaient pas jugées importantes dès le départ. Notamment, les relevés en chaque station étaient initialement faits toutes les heures. A partir de 2012 les hauteurs d'eau ont été mesurées et enregistrées tous les quarts d'heure. Ainsi, nous avons mis en place plusieurs mesures : lorsque des données manquaient de manière ponctuelle, nous procédions à une interpolation linéaire. Nous avons considéré que les valeurs représentant une variation de hauteur d'eau de plus de 40 cm sur 15 minutes étaient anormales. En cas de dépassement de seuil, la hauteur d'eau devient égale à la précédente. Enfin, nous ne nous sommes servis que de relevés heure par heure pour gommer la différence entre les périodes avant/après 2012. Ces quelques mesures (quoique très basiques) permettent déjà de réduire considérablement le nombre de données inexploitable dans notre cas d'études. Nous verrons dans la partie réduction de données pourquoi il n'a pas été nécessaire d'aller plus loin.

- Intégration des données : Plusieurs types de données peuvent être utilisés comme source d'information. Dans notre cas nous disposons de deux types : les hauteurs d'eau relevées en chaque station hydraulique et des indices d'intensité des intempéries relevés apportés par des stations pluviométriques.

Remarque : les données pluviométriques, quoique disponibles, n'ont pas encore eu le temps d'être intégrées à nos modèles statistiques.

Concernant les hauteurs d'eau, nous verrons que nous fournirons à nos algorithmes non pas les données brutes mais des combinaisons des données : variations d'eau sur des échelles de temps, variations quadratiques, etc.

- Transformation des données : Transformer ces données est une étape sensible pour la bonne utilisation de modèles statistiques. En effet, ils peuvent être plus ou moins sensibles à la forme du jeu de données. Par exemple, un réseau de neurones de type multiperceptron multicouches aura tendance à préférer des données standardisées entre 0 et 1. Dans notre cas nous recentrons les séries temporelles de hauteurs d'eau en chaque station. Une renormalisation est faite par rapport à la variance totale des données observées. D'autres techniques plus poussées peuvent encore améliorer l'efficacité des algorithmes mais nous ne les traiterons pas ici.
- Réduction des données : La masse de données dont nous disposons initialement est relativement importante (quelques 120000 points au départ). Il serait pourtant dommageable de fournir directement ces données. Cela aurait pour effet d'impacter le temps d'entraînement des modèles sans pour autant en améliorer les résultats. Une sélection d'un sous-ensemble de données est alors réalisée. Nous ne retiendrons que les données en temps de crues (ie. les périodes où un pic de hauteur d'eau est remarqué à Toulouse, généralement au delà de 2m40 d'eau au niveau de la station Pont Neuf). Nous nous limitons à une fréquence de mesure de l'ordre de l'heure. Bien que les relevés

d'après 2012 nous fournissent des mesures par quart d'heure, il n'a pas paru pertinent au service de prévision des crues de Toulouse de travailler sur de telles fréquences.

6.1 Choix de sélection des données

Dans notre cas, il est important d'insister sur le fait que seules les périodes de crues sont conservées comme base d'entraînement de nos modèles. La première raison, citée précédemment, concerne la vitesse d'entraînement du modèle. Celle-ci quoique raisonnable n'est pas essentielle dans notre cas. Brièvement nous nous contenterons de dire que sur les machines mises à disposition au CERFACS, la phase d'entraînement des modèles statistiques mis en place dans ce projet n'a jamais duré plus d'1h sur la base de données complètes de 120000 points. Le second élément de réponse qui a été déterminant dans le choix de ne garder que les périodes de crues vient de la nature même des données. En effet, la vitesse de propagation de l'eau est différente en temps de crue et en temps de normal. Les débits étant plus intenses en période de crue, l'écoulement se fait plus rapide. Un évènement hydrologique apparaissant en amont arrivera donc plus vite au niveau de Toulouse. S'entraîner sur l'échantillon complet de données provoque un retard de prédiction. Le modèle n'arrivant pas à s'ajuster facilement à ce cas de figure minoritaire dans le jeu de données (les périodes de crues de représentent que 2500 points). Figure 5, on peut comparer la différence entre deux mêmes modèles de prédiction (ici ce sont des modèles linéaires basés sur l'historique de hauteurs d'eau aux stations en amont de Toulouse). D'un côté le modèle est entraîné sur le jeu d'entraînement complet, provoquant un fort retard de prédiction. De l'autre, le modèle n'est entraîné que sur les périodes de crue, diminuant de façon conséquente le retard de prévision.

Maintenant analysons brièvement la nature de quelques crues.




Figure 5: Comparaison des prédictions de deux mêmes régression linéaires, l’une entraînée sur tout le jeu d’entraînement, la seconde sur des phénomènes de crues uniquement

6.2 Analyse de quelques crues

Les crues étudiées dans notre cas sont survenues entre 2005 et 2015. Ce sont des phénomènes ponctuels sur une année. En moyenne un évènement de crue dure entre un et deux jours.

Les crues sont définies comme des événements pendant lesquels la hauteur d’eau à Toulouse a été au delà de deux mètres d’eau. Toutefois elles peuvent atteindre une hauteur de quatre mètres d’eau sur notre échantillon de données, relevant des comportements tout à fait distincts des unes aux autres. Certaines d’entre elles comportent deux pics de crue bien distincts. Dans ces cas là on ne considère tout de même qu’un seul événement.

7 Prédiction des temps d’écoulement entre stations

Suivant le problème posé, certaines stations de mesure de hauteurs d’eau peuvent ne pas avoir d’importance. Il est donc nécessaire de les sélectionner de façon pertinente. Par exemple, certaines stations situées trop en amont de Toulouse n’auront que peu ou pas d’influence si l’échéance de prédiction est courte. Cependant il sera nécessaire de les prendre en compte si nous voulons faire des prédictions à des échéances beaucoup plus longues.

Pour deux problèmes posés, le service de prévision des crues nous a fourni une liste des

stations pertinentes :

1. Pour une prédiction à 4h d'échéance : deux stations ont été retenues, à savoir Auterive et Marquefave. Le temps d'écoulement entre ces deux stations et Toulouse est d'environ 4h.
2. Pour une prédiction à 6h d'échéance : cinq stations ont été sélectionnées en amont de Toulouse, à savoir Mancieux, Mas d'Azil, Roquefort, Saverdun et Mazères qui sont à environ 6h de Toulouse en temps d'écoulement.

Une des questions annexe posée dans ce projet a été de déterminer les temps d'écoulement entre les stations d'observations et notre station d'intérêt : Toulouse Pont-Neuf.

Deux estimateurs ont été identifiés : le premier basé sur le maximum de corrélation des séries temporelles, le second sur la différence de temps entre les pics de crue observés.

7.1 Estimateur de corrélation croisée

Prenons le cas d'une crue observée en juin 2012. Le graphe suivant (Figure 6) met en lumière la hauteur d'eau observée en deux stations : Aspet et Toulouse.




Figure 6: Crue observée en juin 2012 aux stations Aspet et Toulouse

La corrélation des deux séries temporelles vaut :

$$\text{Corr}_{\text{Asp/Tls}} = h_t^{\text{Tls}} \times h_t^{\text{Asp}} + h_{t+1}^{\text{Tls}} \times h_{t+1}^{\text{Asp}} + \dots + h_{t+n}^{\text{Tls}} \times h_{t+n}^{\text{Asp}}$$

Cet indice de corrélation a été calculé pour un décalage temporel nul.

Maintenant nous pouvons également calculer le coefficient de corrélation entre Aspet et Toulouse pour le signal translaté temporellement de 1h, 2h, etc.

Par exemple, le coefficient de corrélation pour Toulouse translaté à +1h vaut :

$$\text{Corr}_{\text{Asp/Tls}}(+1h) = h_{t+1}^{\text{Tls}} \times h_t^{\text{Asp}} + h_{t+2}^{\text{Tls}} \times h_{t+1}^{\text{Asp}} + \dots + h_{t+n+1}^{\text{Tls}} \times h_{t+n}^{\text{Asp}}$$

La figure 7 (graphe des corrélations croisées) montre l'évolution de la corrélation entre les signaux Toulouse/Aspet, lorsque le signal obtenu à Toulouse est décalé à +N heures (ie. quand il est translaté vers la gauche).




Figure 7: Corrélations croisées des signaux de hauteurs d'eau entre Aspet et Toulouse

On s'aperçoit que dans ce cas les signaux sont très corrélés entre 6h et 8h, signifiant que le temps de propagation de la crue met entre 6h et 8h pour aller de Aspet jusqu'à Toulouse.

7.2 Estimateur de la différence de pics de crues

Une seconde estimation consisterait à observer la différence entre les pics de crue à Aspet et Toulouse. La figure 8 illustre cet estimateur qui demeure bien plus sensible que celui basé sur les corrélations.




Figure 8: Comparaison des pics de crue observés à Aspet et Toulouse en juin 2012

Il arrive fréquemment que le pic de crue s'étale sur plusieurs heures, rendant ainsi l'estimation hautement incertaine.

7.3 Agrégation des deux estimateurs

L'estimateur du maximum de corrélation croisée est plus robuste que celui basé sur la différence des pics observés. Cependant, comme nous l'avons vu figure 7, il est fréquent que la courbe hésite entre plusieurs candidats. L'estimateur agrégé est essentiellement basé sur le maximum de corrélation mais donne tout de même une importance accessoire au second estimateur de réduire le doute. Arbitrairement, nous avons choisi de baser 95% sur la prédiction apportée par l'estimateur par maximum de corrélation et 5% sur la différence de pics

observés :

$$\hat{\theta}_{\text{final}} = 0.95 \times \max_{n \in \mathbf{N}} \text{Corr}_{\text{Asp/Tls}}(n) + 0.05 \times |\max h_{\text{Tls}} - \max h_{\text{Asp}}|$$

7.4 Estimation du temps de propagation pour quelques stations

Nous avons estimé le temps de propagation de cinq stations par rapport à Toulouse. Il s'agit de stations connues pour être aux environs de 6h de Toulouse (Mancioux, Saverdun, Roquefort sur Garonne, Mazères et Mas d'Azil). Ces valeurs nous ont été données par le service de prévision des crues.

Trois stations sont prédites à 6h de durée d'écoulement de Toulouse et une est prédite à 7h. Ces résultats sont satisfaisants.

La dernière stations, Mazères, est prédite comme étant à 0h d'écoulement de Toulouse. Ce résultat s'explique par la situation géographique de Mazères. De nombreuses crues sont observées au niveau de Mazères après avoir été observées au niveau de Toulouse. Il arrive régulièrement que le pic de crue soit observé en retard à Mazères.

8 Modèle de prédiction à 4h

8.1 Présentation du cas d'étude


Prédire la hauteur d'eau à Toulouse à 4 heures d'échéance nous a permis de comprendre les enjeux et les besoin du service de prévision des crues de Toulouse. Il s'agit d'un cas simple où l'échéance de prévision, plutôt courte, permet de limiter le cas d'études à deux affluents situés à peine en amont de Toulouse.

Ce cas de figure nous a servi de cas jouet. Il nous a principalement permis de prendre en main les données, de comprendre les attentes du service de prévision des crues et de tester

le comportement de quelques algorithmes statistiques.

8.1.1 Cartographie des stations d'intérêt et commentaires

Trois stations sont utilisées pour ce cas de prédiction. Les deux stations amont (Auterive et Marquefave) ont été choisies car leur distance à Toulouse pour les phénomènes d'écoulement est d'environ 4h (ie. qu'une intensification du débit remarquée à un instant t à Auterive sera observée au niveau de Toulouse à l'instant $t+4h$). Les stations ont l'avantage de surveiller les deux affluents principaux de la Garonne au niveau de Toulouse (Figure 9).



8.2 Base d’entraînement des modèles

Nous restreignons la base d’entraînement aux crues arrivées entre 2005 et 2015, totalisant vingt crues. Les 12 premières (de 2005 à juin 2012) seront réservées à la phase d’entraînement du modèle. Les 8 autres serviront d’échantillons de validation.

8.3 Modèle baseline SPC

Le modèle initial que nous utilisons a été proposé par le service de prévision des crues. Il s’agit d’un modèle linéaire dont les coefficients ont été ajustés par dires d’experts. Il prend en entrée les deltas de débits d’eau à Auterive et à Marquefave et renvoie le delta de débit prédit à Toulouse 4h plus tard :

$$(Q_{t+4h}^{Tls} - Q_t^{Tls}) = a_1 \times (Q_t^{Mar} - Q_{t-4h}^{Mar}) + a_2 \times (Q_t^{Aut} - Q_{t-4h}^{Aut})$$

En particulier, les coefficients valent ici : $(a_1, a_2) = (0.9, 1)$

Ce modèle, quoique très basique, prend en compte l’aspect linéaire des débits d’eau et donne des résultats pertinents au regard d’autres algorithmes statistiques plus complexes.

Remarque : le modèle statistique fournit un delta de débit, pourtant les résultats sont analysés en hauteur d’eau. En effet, pour des questions de linéarité et pour renforcer l’efficacité de nos modèles statistiques nous jugeons préférable de ne les laisser travailler que sur des débits. Une fois le résultat du modèle obtenu en débit, nous opérons une conversion manuelle par le biais des courbes de tarage. Il ne faudra donc pas s’étonner que nous ne jugions de l’efficacité d’un modèle en observant les erreurs de prédiction en hauteur d’eau (car c’est l’objectif défini par le SPC) alors que le modèle statistique renvoie un delta de débits.

Analysons maintenant les résultats obtenus par des modèles plus complexes.

8.4 Résultats des modèles statistiques

Nous avons mis en place cinq modèles statistiques différents : régression linéaire, machine à vecteurs supports, gradient boosting, ϵ -SVR et un réseau de neurones de type MLP.

La formulation du problème reste identique pour tous les modèles. Ils disposent comme variables d'entrée les deltas de débits observés en amont sur les six dernières heures. En sortie des modèles, on cherche le delta de débit prévu à Toulouse sur les 6 prochaines heures.

Remarque : Les modèles statistiques renvoient des deltas de débits d'eau. Ces résultats sont ensuite convertis en hauteurs d'eau par le biais des courbes de tarage.

Les résultats obtenus avec le modèle du SPC sont tout à fait équivalents au résultats que nous pouvons obtenir avec des modèles plus complexes¹. D'après les outils de mesure du service de prévision des crues, une différence de hauteur d'eau de moins de deux centimètres n'est pas significative. Ainsi, les moyennes des erreurs absolues ainsi que les valeurs de quantile à 90% sont considérées comme équivalentes entre tous les modèles. De même, les indices de

Table 1: Tableau récapitulatif des résultats de prédiction pour chaque modèle statistique

	SPC	reg_lin	grad_boost	ϵ -SVR	MLP
erreur moyenne (cm)	2.89	2.82	2.79	2.77	2.88
quantile 90% (cm)	8.82	8.49	8.92	9.2	8.56
erreur max (cm)	26.39	27.64	32.58	28.78	26.54

persistance et d'efficience sont tous du même ordre (Figure 10).




Figure 10: Résultats de différents modèles statistiques pour les critères de persistance et d'efficience

Dans ces conditions, il est logique de privilégier le modèle le plus simple, à savoir celui du service de prévision des crues.

8.5 Commentaires




Figure 11: Corrélation des débits entre les stations en amont et Toulouse Pont-Neuf

Etant donnée la simplicité du cas de figure, il est difficile d'obtenir de bien meilleurs résultats que le modèle baseline. En effet, la difficulté ne vient pas de la limite du modèle statistique à s'adapter aux conditions mais du bruit sur les données. La linéarité du problème énoncé en terme de débits a bien été prise en compte par les modèles. Il est possible de gagner quelques dixièmes de centimètres sur l'indice de mae mais globalement le risque de pire prévision reste le même.

La situation suivante est un peu plus complexe. Elle demande de prévoir la hauteur d'eau à Toulouse à une échéance plus longue : 6h. Nous allons voir que le problème physique devient plus complexe et que les relations de débits ne sont plus aussi directes et intuitives.

9 Modèle de prédiction à 6h

9.1 Présentation du cas d'étude

Dans le cas présent nous souhaitons prédire la hauteur d'eau au niveau de Toulouse à une échéance de 6h. Il devient plus complexe que le modèle de prédiction à échéance de 4h en laissant place à davantage de phénomènes non linéaires entre stations. Si l'objectif reste identique (on essaie toujours de prédire une hauteur d'eau au niveau de Toulouse Pont-Neuf), les stations amont s'en trouvent changées. Cette fois-ci nous considérons les cinq stations Mas d'Azil, Mazères, Roquefort sur Garonne, Mancieux et Saverdun.

Nous allons implémenter plusieurs algorithmes statistiques et les comparer une nouvelle fois au modèle fourni par le service de prévision des crues.

Pour rappel, l'entraînement des modèles se fait sur 12 événements de crues (survenues entre 2005 et 2013). Les 8 crues suivantes (de 2013 à 2015) servent d'échantillons de validation.

9.1.1 Cartographie des stations d'intérêt et commentaires

Les stations sélectionnées en amont de Toulouse (cf. Figure 12) ont cette fois-ci la particularité d'être à une distance de propagation d'eau de Toulouse de 6h.

Nous avons retenu cette liste de stations conformément aux choix du service de prévision des crues. Bien que ce travail n'ait pour le moment pas été réalisé, il pourrait être intéressant d'en sélectionner davantage. En effet, une pluie intense située en aval des stations d'observation, ou des intempéries sur le tronçon surveillé par la station Pailhès pourraient être à l'origine d'une crue à Toulouse que nous ne verrions pas en ne gardant que les cinq premières stations.

Remarque : les stations situées plus en amont n'ont pas été sélectionnées car, a priori, un événement qui s'y passerait serait visible plus en aval, aux stations que nous avons sélectionnées.



Figure 12: Cartographie des stations d'intérêt pour une prédiction à échéance de 6h

9.2 Modèle baseline SPC

Une nouvelle fois, le modèle de départ est donné par le service de prévision des crues. Il s'agit également d'un modèle linéaire basé sur les variations de débits où les coefficients sont ajustés par dires d'experts :

$$\begin{aligned} \Delta Q_{Tls}(t, t + 6h) = & 0.65\Delta Q_{Maz}(t - 6h, t) + 0.91\Delta Q_{Man}(t - 6h, t) + 0.7\Delta Q_{Roq}(t - 6h, t) \\ & + 0.4\Delta Q_{Sav}(t - 6h, t) + 3\Delta Q_{Mas}(t - 6h, t) \end{aligned}$$

où $\Delta Q_{Mas}(t - 6h, t) = Q_t^{Mas} - Q_{t-6h}^{Mas}$ représente la variation de débit observée sur les six dernières heures à la station Mas d'Azil.

Cette fois-ci un modèle linéaire ne permettra pas d'obtenir un résultat optimal. Sur la même crue que montrée Figure 11, les corrélations réalisées avec les stations amont à 6h de distance de propagation font intervenir davantage de phénomènes non linéaires (cf. Figure 13).

Une première idée va être d'entraîner des outils statistiques plus complexes partant d'un même cadre d'apprentissage.




Figure 13: Corrélation des signaux de débits entre les stations amont et Toulouse Pont-Neuf à 6h d'intervalle

9.3 Premiers modèles pour toutes les méthodes

Dans un premier temps, modèle linéaire, gradient boosting et réseau de neurones de type MLP disposent des mêmes entrées que le modèle SPC, à savoir les deltas de débits ΔQ observés aux stations amont sur les six dernières heures.

Les résultats sont sensiblement identiques (voire même moins bons) au modèle du SPC (cf. Table 2 et Figure 14). La régression linéaire obtient un score légèrement supérieur mais non significatif compte tenu des ordres de grandeur des outils de mesures utilisés.

Table 2: Tableau récapitulatif des résultats de prédiction pour chaque modèle statistique

	SPC	reg_lin	grad_boost	MLP
erreur moyenne (cm)	4.07	3.72	4.05	4.27
quantile 90% (cm)	17.88	12.47	17.07	18.11
erreur max (cm)	44.33	43.5	44.06	47.42




Figure 14: Résultats de différents modèles pour les critères de persistance et d'efficacité

L'information dont dispose nos modèles pour réaliser une prédiction de hauteur d'eau est assez faible. L'étape suivante consiste à rajouter des paramètres au modèle.

9.4 Feature engineering

Une idée va être d'exploiter la linéarité du modèle SPC et de la régression linéaire, et d'y ajouter une information non linéaire par dessus. Pour ce faire, on réalise un premier niveau de prédiction avec le modèle SPC. La sortie obtenue devient alors une entrée pour des modèles plus complexes (ici la régression linéaire, le gradient boosting et le réseau de neurones MLP). On rajoute ensuite d'autres entrées, notamment une information sur la hauteur d'eau est les variations quadratiques de débit. La figure 15 donne un schéma simplifié de la structure de ce nouvel estimateur.




Figure 15: Schéma simplifié de la structure du nouvel estimateur de débit à Toulouse Pont-Neuf

Les résultats obtenus sont très encourageants. Si l'erreur absolue n'a pas diminué significativement en moyenne, le risque de pire prédiction diminue à moins de 30cm pour l'algorithme de gradient boosting, et légèrement plus pour les deux autres : environ 33cm (cf. Table 3). De même les indices de persistance et d'efficacité sont améliorés jusqu'à dépasser le seuil de 80% de persistance et de 98% d'efficacité pour l'estimateur par gradient boosting (cf. Figure 16).

Table 3: Tableau récapitulatif des résultats de prédiction pour chaque modèle statistique

	SPC	reg_lin	grad_boost	MLP
erreur moyenne (cm)	4.07	3.71	3.55	3.83
quantile 90% (cm)	17.86	11.41	13.34	12.22
erreur max (cm)	44.33	33.4	29.6	34.28




Figure 16: Persistance et efficience des différents modèles statistiques après feature engineering

9.4.1 Commentaires sur les erreurs commises

Les erreurs sont commises à des endroits très différents. Si certains pics de crue sont bien prédits, d'autres le sont moins. L'algorithme de gradient boosting prédit mal le premier pic de la crue du 3 novembre 2013 (voir Figure 17) mais prédit mieux les autres. Des erreurs de prédiction sont commises par l'ensemble des modèles ; c'est notamment le cas du second pic de cette même crue du 3 novembre.

A l'occasion de montées des eaux brutales, MLP et gradient boosting s'adaptent mieux que le modèle du SPC en rattrapant un certain retard de prévision dans la phase de montée. Ce phénomène se visualise sur la crue du 30 mars 2014, où tous les modèles possèdent un certain retard dans la montée du premier pic de crue (Figure 19).

10 Conclusion

Dans ce projet nous avons cherché à mettre en place une série de modèles de prédiction de la hauteur d'eau au niveau de Toulouse. Nous disposons au départ d'un historique de hau-

teurs d'eau mesurées sur la Garonne et ses affluents. En tout, ce sont vingt-deux stations de mesure qui surveillent les cours d'eau en amont de Toulouse (côté Pyrénées), et ce en temps réel. Disposant d'une base de données conséquente, nous avons choisi une approche statistique.

Plusieurs problèmes se sont posés. D'une base de données plutôt conséquente au départ (environ 120000 points d'observations), une grande partie correspondait à des périodes de non crue à Toulouse. Entraînés sur la totalité de la base de données, les modèles statistiques ont donné de mauvais résultats. Le comportement de la Garonne et de ses affluents étant sensiblement différent par de temps crue, nous avons dû réduire drastiquement la quantité de données sélectionnée pour entraîner nos modèles. De près de 120000 points, nous sommes passés aux environs de 2500 points (en se restreignant aux données conseillées par le service de prévision des crues).

Le parc de stations de surveillance en Occitanie est vaste. Parmi les vingt-deux stations d'observation en notre possession, certaines sont situées jusque dans les Pyrénées espagnoles. Une seconde fois, nous avons choisi de réduire la quantité d'observations en réduisant le nombre de stations considérées. Leur sélection a été basée sur leur distance à Toulouse. Pour une échéance de prédiction à 4h, Marquefave et Auterive (d'où l'eau met environ 4h à s'écouler jusqu'à Toulouse) nous ont paru être les plus pertinentes. De même, pour une prévision à échéance de 6h, seules cinq stations (Roquefort, Saverdun, Mancieux, Mas d'Azil et Mazères) ont été retenues car l'eau met environ 6h à s'écouler jusqu'à Toulouse.

Ces stations ont été choisies par le service de prévision des crues. Nous avons cherché à estimer par nous-mêmes le temps de propagation de l'eau entre les stations amont et Toulouse. Deux estimateurs nous ont semblé naturels : le premier reposant sur la différence des pics de crue, le second basé sur le maximum des corrélations croisées. Concernant les stations connues pour être à 6h de Toulouse (confirmées par le SPC), dans quatre cas sur cinq nous prédisons un temps de propagation de 6 ou 7h. Pour la cinquième station (Mazères), le

résultat est faux. Plusieurs raisons expliquent cette mauvaise prédiction. D'une part, le pic de crue est souvent observé plus tard à Mazères qu'à Toulouse (cela s'explique par la topographie du terrain). D'autre part on observe que, pour les crues composées de deux pics, le second est souvent plus important à Mazères (on observe le phénomène inverse à Toulouse). Par dessus tout, zéro crue de la base de donnée n'a été pilotée par le bras d'eau observé à Mazères. Il manque donc de l'information.

Enfin, nous avons implémenté plusieurs modèles de prédiction à 4 et 6h d'échéance.

Le cas à 4h nous a permis de comprendre les enjeux du problème ainsi que les attentes du service de prévision des crues. Dans ce cas de figure, nous avons mis en place quelques modèles de prédiction (régression linéaire, ϵ -SVR, gradient boosting, MLP). La cartographie rend le problème relativement simple. Les deux principaux bras d'eau menant à la Garonne toulousaine sont surveillés par deux stations d'observation : Auterive et Marquefave. Négligeant certains phénomènes physiques comme l'épuration, l'absorption de l'eau par les sols ou les intempéries, le débit entrant à Toulouse est alors la somme des débits observés à Marquefave et à Auterive. Une échéance de prédiction à 4h est suffisamment courte pour négliger ces phénomènes mais ce n'est plus le cas pour des échéances plus longues telles que 6h, 8h ou plus.

Un modèle linéaire, tel que celui proposé par le service de prédiction des crues, réalise des résultats très satisfaisants dans ce cas de figure. Sans données supplémentaires (autres que les débits d'eau observés à Auterive et Marquefave), il reste difficile d'obtenir un modèle plus performant.

L'objectif véritable de ce stage aura été de concevoir un modèle capable de prédire de manière raisonnable le niveau d'eau au niveau de Toulouse à échéance de 6h. Le modèle apporté par le service de prévision des crues montre ici ses limites. La non-linéarité des phénomènes met en péril des algorithmes exclusivement linéaires comme celui du SPC. Une solution est apportée

en fournissant de l'information supplémentaire sur les variations quadratiques de débit. Gradient boosting et MLP parviennent à réaliser de meilleurs scores dans ce cas présent. La pire prévision réalisée par le gradient boosting est abaissée à environ 29cm d'erreur absolue (contre environ 43cm pour le modèle SPC).

Cependant ces résultats sont à mettre au regard de la quantité de données mises à notre disposition. Seulement douze crues ont été retenues comme données d'entraînement. Huit autres forment notre échantillon de validation. La quantité de données reste faible. Elle ne nous permet pas d'avoir suffisamment de recul si jamais une crue différente de notre jeu de données devait être analysée. Notamment, de 2005 à 2015, aucune crue n'a été pilotée (n'est issue) par le bras d'eau surveillé par Mazères. Si une telle crue devait se produire demain, quels seraient les résultats apportés par nos modèles? De même, la crue la plus haute observée entre 2005 et 2015 n'a pas dépassé les quatre mètres d'eau. La crue de l'an 2000 avait dépassé le seuil de 4m30.

Au regard de certaines prédictions sur les crues de validation, des retards de prédiction ont été remarqués. Il serait intéressant d'étudier la réaction des algorithmes statistiques face à l'ajout d'autres types de données : mesures pluviométriques, lames d'eau ANTILOPE [ant], humidité des sols, etc.

Ainsi, dans la suite du stage, nous augmenterons le jeu de données avec les crues survenues après 2015. Quelques crues seront consacrées à former un jeu de test, pour limiter le sur-ajustement lié au jeu de validation. Nous disposons également de quelques données pluviométriques. Elles seront également rajoutées aux données d'entrée de nos modèles.

A plus long terme, il serait intéressant de rajouter un indice de confiance sur la qualité de la prédiction apportée par un modèle, éventuellement par le biais d'une quantification d'incertitude.

References

- [Aga15] Vivek Agarwal. Research on data preprocessing and categorization technique for smartphone review analysis. *International Journal of Computer Applications*, 131:30–36, 12 2015.
- [ant] Données antilope. http://wikhydro.developpement-durable.gouv.fr/index.php/B.04_-_Estimation_d%27une_pluie_de_bassin_par_observation_RADAR.
- [cru] Le déluge de pentecôte. <https://www.ladepeche.fr/article/2000/06/12/99522-le-deluge-de-pentecote.html>.
- [CSA03] Marina Campolo, Alfredo Soldati, and Paolo Andreussi. Artificial neural network approach to flood forecasting in the river arno. *Hydrological Sciences Journal*, 48(3):381–398, 2003.
- [CV95] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, Sep 1995.
- [DRE] Direction régionale de l’environnement, de l’aménagement et du logement (dreal) occitanie. <http://www.occitanie.developpement-durable.gouv.fr/presentation-organigramme-plaquette-r7800.html>.
- [Fri01] Jerome H Friedman. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, pages 1189–1232, 2001.
- [GGH91] Jean-Charles Galland, Nicole Goutal, and Jean-Michel Hervouet. Telemac: A new numerical model for solving shallow water equations. *Advances in Water Resources*, 14(3):138–148, 1991.
- [Hel] Helios group. <http://cerfacs.fr/helios/>.

- [LIB04] A LIBSVM. Library for support vector machines, chih-chung chang and chih-jen lin. *Computer Science Department, National Taiwan University*. Available: <http://www.csie.ntu.edu.tw/~cjlin/libsvm>, 2004.

- [MD00] Holger R Maier and Graeme C Dandy. Neural networks for the prediction and forecasting of water resources variables: a review of modelling issues and applications. *Environmental modelling & software*, 15(1):101–124, 2000.

- [PVG⁺11] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

- [Sap06] Gilbert Saporta. *Probabilités, analyse des données et statistique*. Editions Technip, 2006.

- [SPC] Dreal occitanie - service de prévision des crues. <http://www.occitanie.developpement-durable.gouv.fr/la-prevision-des-crues-r5682.html>.

- [WCL08] CL Wu, KW Chau, and YS Li. River stage prediction based on a distributed support vector regression. *Journal of hydrology*, 358(1-2):96–111, 2008.

11 Annexe




Figure 17: Prédictions sur la crue du 3 novembre 2013




Figure 18: Prédictions sur la crue du 17 novembre 2013




Figure 19: Prédiction sur la crue du 30 mars 2014




Figure 20: Prédiction sur la crue du 22 mai 2015